Fourierova analiza

Diskretna Fourierova transformacija

Jakob Jerič, 28221068
Fakulteta za matematiko in fiziko, Univerza v Ljubljani
jj06142@student.uni-lj.si

14. november 2024

Naloga

1. Izračunaj Fourierov obrat Gaussove porazdelitve in nekaj enostavnih vzorcev, npr. mešanic izbranih frekvenc. Za slednje primerjaj rezultate, ko je vzorec v intervalu periodičen (izbrane frekvence so mnogokratniki osnovne frekvence), z rezultati, ko vzorec ni periodičen (kako naredimo Gaussovo porazdelitev 'periodično' za FT?). Opazuj pojav potujitve na vzorcu, ki vsebuje frekvence nad Nyquistovo frekvenco. Napravi še obratno transformacijo in preveri natančnost metode. Poglej, kaj se dogaja z časom računanja - kako je odvisen od števila vzorčenj?

2. Po Fourieru analiziraj 2.3 s dolge zapise začetka Bachove partite za violino solo, ki jih najdeš na spletni strani Matematičnofizikalnega praktikuma. Signal iz začetnih taktov partite je bil vzorčen pri $44,100$ Hz, $11,025$ Hz, 5512 Hz, 2756 Hz, 1378 Hz in 882 Hz. S poslušanjem zapisov v formatu `.mp3` ugotovi, kaj se dogaja, ko se znižuje frekvenca vzorčenja, nato pa s Fourierovo analizo zapisov v formatu `.txt` to tudi prikaži.

Uvod

Pri numeričnem izračunavanju Fourierove transformacije

$$H(f) = \int_{-\infty}^{\infty} h(t) \exp(2\pi \mathrm{i} f t)\, \mathrm{d}t \tag{1}$$

$$h(t) = \int_{-\infty}^{\infty} H(f) \exp(-2\pi \mathrm{i} f t)\, \mathrm{d}f \tag{2}$$

je funkcija $h(t)$ običajno predstavljena s tablico diskretnih vrednosti

$$h_k = h(t_k), \quad t_k = k\Delta, \quad k = 0, 1, 2, \ldots N-1. \tag{3}$$

Zaradi tega smo omejeni na končno mnogo točk, v katerih poznamo vrednost funkcije $h(t)$. Ker smo vzorčili z vzorčno frekvenco $f = 1/\Delta$, za tako definiran vzorec obstaja naravna meja frekvenčnega spektra, ki se imenuje *Nyquistova frekvenca*, $f_c = 1/(2\Delta)$: harmonični val s to frekvenco ima v vzorčni gostoti ravno dva vzorca v periodi. Če ima funkcija $h(t)$ frekvenčni spekter omejen na interval $[-f_c, f_c]$, potem ji z vzorčenjem nismo odvzeli nič informacije; kadar pa se spekter razteza izven intervala, pride do *potujitve* (*aliasing*), ko se zunanji del spektra preslika v interval.

Frekvenčni spekter vzorčene funkcije (3) računamo samo v N točkah, če hočemo, da se ohrani količina informacije. Vpeljemo vsoto

$$H_n = \sum_{k=0}^{N-1} h_k \exp\left(\frac{2\pi \mathrm{i} kn}{N}\right), \qquad n = -\frac{N}{2}, \ldots, \frac{N}{2}, \tag{4}$$

ki jo imenujemo diskretna Fourierova transformacija in je povezana s funkcijo v (1) tako:

$$H\left(\frac{n}{N\Delta}\right) \approx \Delta \cdot H_n.$$

Zaradi potujitve, po kateri je $H_{-n} = H_{N-n}$, lahko pustimo indeks n v enačbi (4) teči tudi od 0 do N. Spodnja polovica tako definiranega spektra ($1 \leq n \leq \frac{N}{2} - 1$) ustreza pozitivnim frekvencam $0 < f < f_c$, gornja polovica ($\frac{N}{2} + 1 \leq N - 1$) pa negativnim, $-f_c < f < 0$. Posebna vrednost pri $n = 0$ ustreza frekvenci nič (»istosmerna komponenta«), vrednost pri $n = N/2$ pa ustreza tako f_c kot $-f_c$.

Ker smo pri diskretni Fourierovi transformaciji omejeni na končen interval časa T, je tudi ločljivost v frekvenčnem spektru omejena na $\Delta f = 1/T$. Težavo dobro demonstrir pojav puščanja, ki namesto frekvence, ki bi bila med dvema, ki sta mnogokratnik osnovne frekvence, pokaže malce čuden rezultat.

Diskretna Fourierova transformacija

Za diskretno Fourierovo transformacijo sem napisal funkcijo, ki je praktično enaka funkciji `DFT_slow` iz spletne učilnice. Ko sem primerjal porabo spomina in časa, je tudi funkcija, ki uporablja zanko, enaka kot funkcija iz spletne učilnice imenovana `DFT_simplest`.

Gaussova porazdelitev

Spodnja grafa prikazujeta transformacijo Gaussove porazdelitve pri različni frekvenci vzorčenja. Tako vzorčenju z $N = 10$ ustreza frekvenca vzorčenja $f_s = 1/T = 1/10 = 0.1$, kar pomeni, da je Nyquistova frekvenca $f_c = 0.5$ Hz. Pri vzorčenju z $N = 1000$ je tako pri enakem T Nyquistova frekvenca $f_c = 50$ Hz. Na naslednjih slikah lahko lepo opazimo, kako število vzorčnih točk N vpliva na frekvenčni spekter signala:

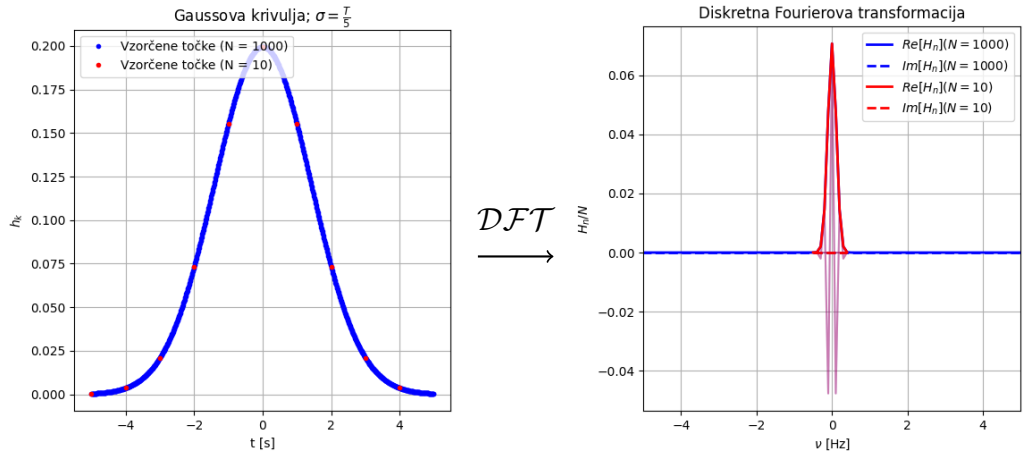

Slika 1: DFT Gaussove porazdelitve s $\sigma = \frac{T}{5}$.

Transformacija brez modulacije je na grafu predstavljena s svetlejšim odtenkom. Čeprav sem transformiral signal, ki ima vrh pri $t = 0$, ga diskretna Fourierova transformacija razume kot signal z vrhom pri $t = \frac{T}{2}$, saj računalnik dobi le spisek z vrednostmi funkcij v diskretnih točkah. Da bi dobili DFT, ki je transformiranka prikazaneha signala, moramo H_n pomnožiti z $e^{-2i\pi\nu\frac{T}{2}}$, saj velja:

$$\mathcal{F}\{h(t+\tau)\} = H(f)e^{2\pi i f\tau}.$$

Težavo bi lahko rešil tudi tako, da bi Gaussovo porazdelitel tako, da bi od $t = 0$ do $t = \frac{T}{2}$ narisal enako funkcijo, od $t = \frac{T}{2}$ do $t = T$ pa del funkcije, ki je sedaj predstavljen na intervalu $[-\frac{T}{2}, 0]$.

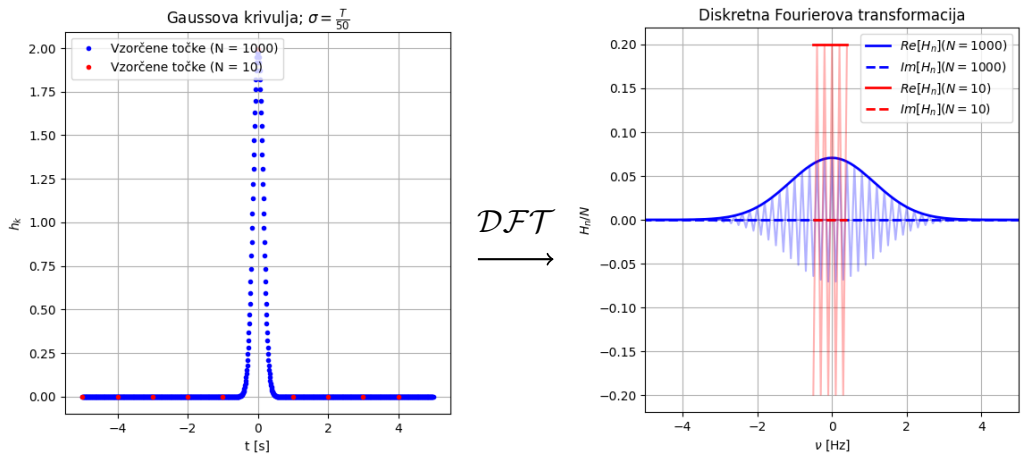

Slika 2: DFT Gaussove porazdelitve s $\sigma = \frac{T}{50}$.

Vidimo, da je kakovost DFT pri določenem N odvisna od vhodnega si-

gnala tako res velja dejstvo iz uvoda: če za zignal velja, da ne vsebuje frekvenc nad Nyquistovo frekvenco, potem je DFT natančen, drugače pa pide do potujitve. Le-to lahko opazimo na sliki 2, ko se frekvence nad 0,5 Hz preslikajo v interval $[-0.5, 0.5]$ Hz. Na zgornjih dveh slikah lahko opazimo tudi 'Heisenbergovo načelo nedoločenosti', ki pravi da ztem večja je σ v časovni odvisnosti, tem manjša je σ v frekvenčnem prostoru.

Potujitev in puščanje

Do potujitve pride, kadar signal vsebuje frekvence, ki so večje od Nyquistove frekvence. Frekvence nad Nyquistovo frekvenco se 'prezrcalijo' v interval $[-f_c, f_c]$. Če bi opazovali sinusni val s frekvenco ν, ki v frekvenčnem spektru predstavlja vrhova pri ν in $-\nu$, ν pa bi povečevali s korakom $\frac{1}{T}$, bise vrhova premikala od izhodišča do Nyquistove frekvence. Ko bi prišli do Nyquistove frekvence, bi se vrhova 'prezrcalila' in se začela premikati v nasprotno smer. S povečevanjem ν bi se tako vrhova 'obijala' v intervalu $[-f_c, f_c]$. Spodnji grafi prikazujejo DFT različnih sinusnih valov s časom trajanja $T = 10$ s. Signal sem vzorčil z azličnima N - $N_1 = 20$ in $N_2 = 1000$. Ker pri N_1 dobimo Nyquistovo frekvenco $f_c = 1$ Hz, nekateri valovi pa imejo $\nu > 1$ Hz, prihaja do potujitve:

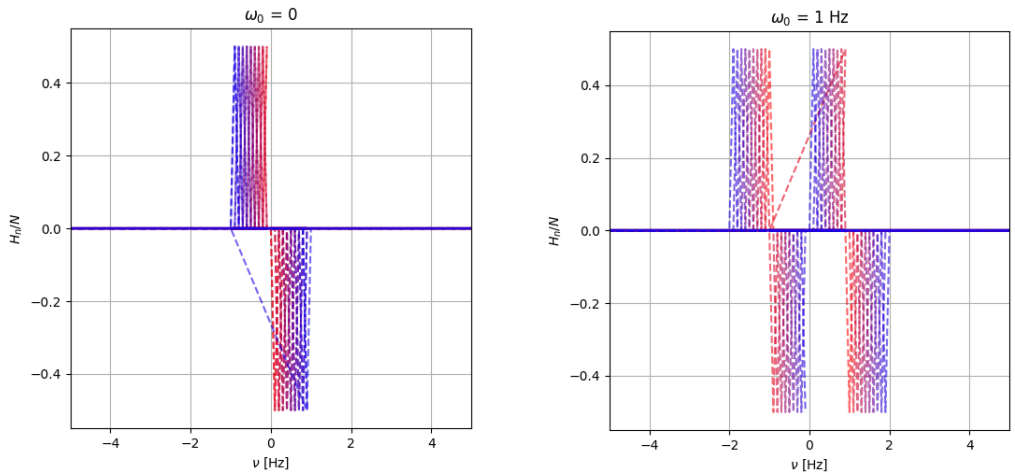

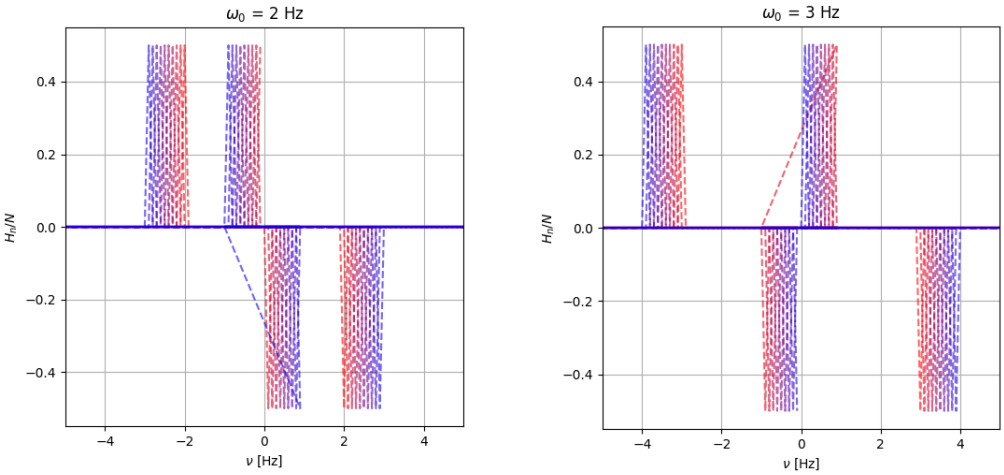

Slika 3: Potujitev pri frekvencah $\nu > 1$ Hz.

Poleg potujitve pa lahko pri diskretni Fourierovi transformaciji pride tud do 'puščanja'. To je povezano z osnovno frekvenco $\frac{1}{T}$. Frekvenčna ločljivost je namreč tudi $\frac{1}{T}$, kar je v mojem primeru 0,1 Hz. To pomeni, da lahko povem kakšna je zastopanost valov s frekvenco 0,1 Hz, 0,2 Hz, 0,3 Hz, itd. Vendar pa je problem, če signal ni večkratnik osnovne frekvence (npr. 0,25 Hz). V tem primeru bo prišlo do puščanja in Zastopane bodo frekvence, ki jih naš signal v resnici sploh ne vsebuje. Spodnji graf prikazuje DFT sinusnih valov s frekvencami 0,2 Hz, 0,25 Hz - rdeča in 0,3 Hz. Namesto, da bi v imaginarnem delu dobili tri vrhove vrhove, ki bi bili po amplitudi in fazi enaki, pri frekvenci 0,25 Hz dobimo realen signal, kjer so zastopane tudi ostale frekvence:

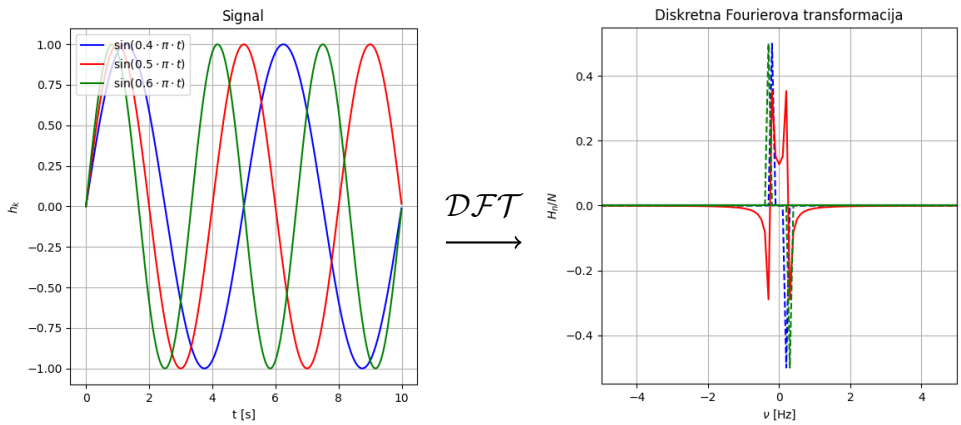

Slika 4: DFT sinusnih valov s frekvencami 0,2 Hz, 0,25 Hz in 0,3 Hz.

Napaka IDFT, časovna in spominska zahtevnost

Sppodnji graf prikazuje signal (kombinacijo sinusov in kosinusov, M = 90 - od zdaj naprej imenovan 'Definiran signal') in njegovo inverzno diskretno Fourierovo transformacijo. Za razliko od navadne inverzne Fourierove transformacije, pri diskretni dobimo le vrednost funkcije v diskretnih točkah vzorčenja. Tako lahko napako inverzne transformacije gledamo kot odstopanje vrednosti IDFT od vrednosti začetne funkcije v teh diskretnih točkah, ali pa kot absoolutno vrednost razlike med začetno funkcijo in IDFT na danem časovnem intervalu T. Spodnja grafa prikazujeta začetni signal, njegovo Fourierovo in inverzno Fourierovo transformacijo ter površino med originalnim grafom in interpolacijo IDFT.

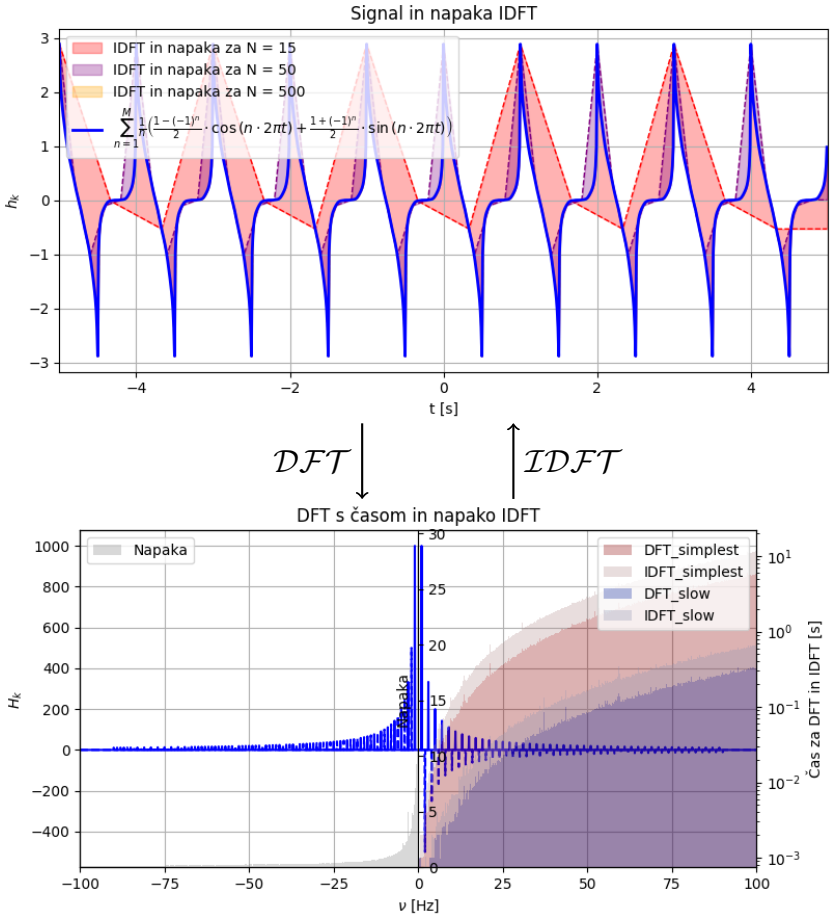

Slika 5: Na desni polovici frekvenčnega spektra je prikazan čas, ki ga je vsaka od funkcij (DFT_slow in DFT_simplest) potrebovala za izračun DFT in IDFT, na levi pa napaka, izražena kot površina med signalom in interpolirano IDFT.

Posamezna vrednost N je na osi ν prikazana kot ustrezna Nyquistova frekvenca.

Lahko pa tudi pogledamo kako se časovna in spominska zahtevnost spreminjata z N. Da bi preveril, ali sta čas in spomin odvisna tudi od vrste signala sem tako oboje meril za 3 različne signale - Definiran signal, konstanten signal ter naključni signal. Spodnji graf prikazuje čas (raztrosen graf), in spomin (črtni graf) potreben za izračun DFT in IDFT:

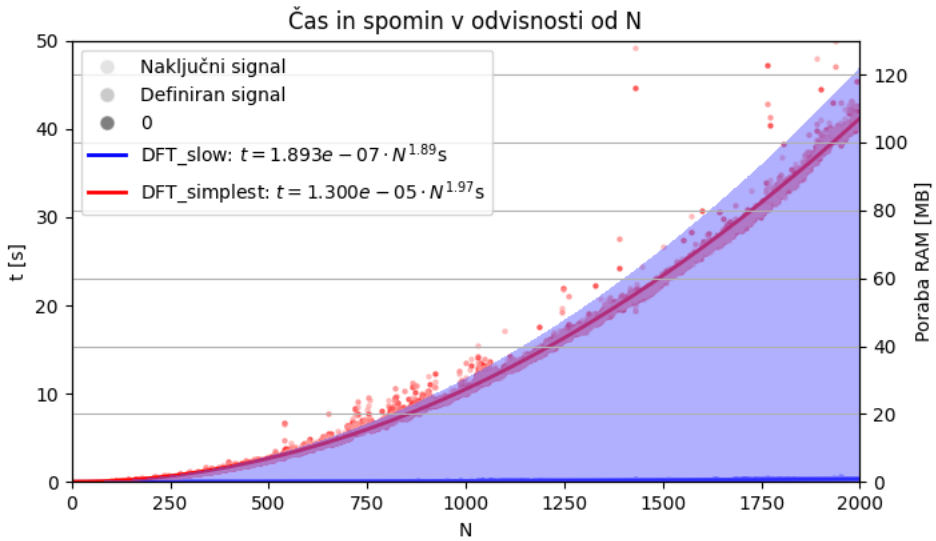

Slika 6: Čas in spomin potreben za izračun DFT in IDFT.

Opazimo, da čas, potreben za izračun DFT, narašča $\propto N^2$ za obe funkciji (s prilagajanjem krivulje sem za DFT_simplest dobil eksponent 1.97±0.05, za DFT_slow pa 1.89±0.07). Zelo hitro lahko opazimo, da je DFT_slow veliko ($\backsim$ 100x) hitrejši od DFT_simplest, kar je tudi pričakovano, saj namesto zanke uporablja linearno algebro. A na račun svoje hitrosti ta funkcija porabi veliko več spomina.

Za različne signale se tako šasovna kot tudi spominska zahtevnost nista bistveno razlikovali.

Kot že omenjeno, lahko napako IDFT gledamo tudi kot površino med originalnim signalom in interpolirano IDFT, ali pa kot odstopanje vrednosti IDFT od vrednosti začetne funkcije v diskretnih točkah vzorčenja. Naslednji graf prikazuje, kako sta obe vrsti napake odvisni od N:

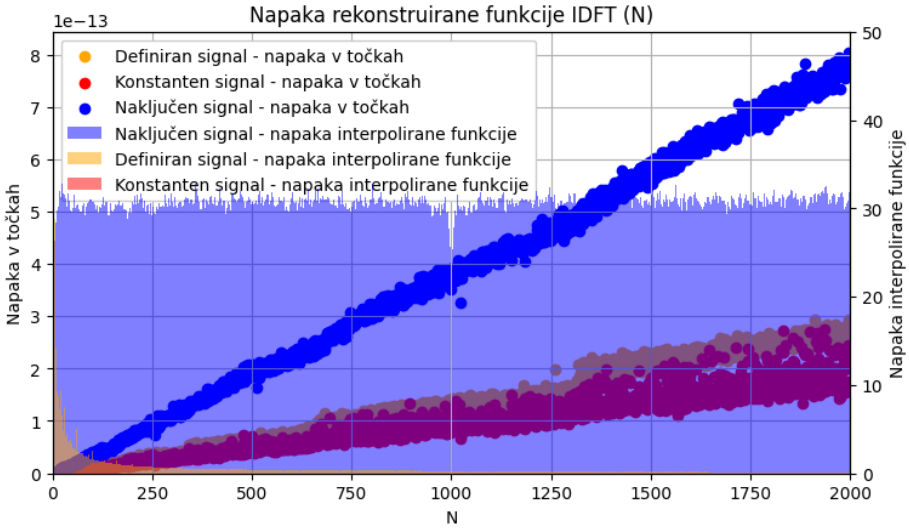

Slika 7: Napaka IDFT v odvisnosti od N.

Kot pričakovano opazimo, da se za definirian signal površina med originalnim signalom in interpolirano IDFT na intervalu T zmanjšuje z večanjem N, medtem ko za naključen signal ta ves čas ostaja enaka - močno je bila odvisna od amplitude signala, kar ni prikazano na grafu. Zanimivo se mi je zdelo, da je pri $N \approx 1000$ napaka izjemno majhna. Ne vem, kaj bi bil lahko vzrok za to.

Česar morda nisem pričakoval, je dejstvo, da odstopanje vrednosti v posameznih točkah vzorčenja z večanjem N dokaj linearno narašča. To je verjetno posledica seštevanja, kjer se napaka povečuje zaradi numeroičnih vzrokov, saj večji N zahteva seštevanje daljše vsote - enačba (4).

Bachova partita

S poslušanjem posnetkov na spletni učilnici lahko ugov+tovimo, da imajo posnetki, ki so bili posneti z nižjo frekvenco vzorčenja nizje zvoke. Ugotovitev se zdi smiselna, saj frekvence nad Nyquistovo frekvenco ne morejo biti zastopane. Naslednji graf prikazuje DFT Bachove partite, ki je bila vzorčena pri 44,100 Hz, 11,025 Hz, 5512 Hz, 2756 Hz, 1378 Hz in 882 Hz, svetlejšimodtenki pomenijo nižj frekvence vzorčenja:

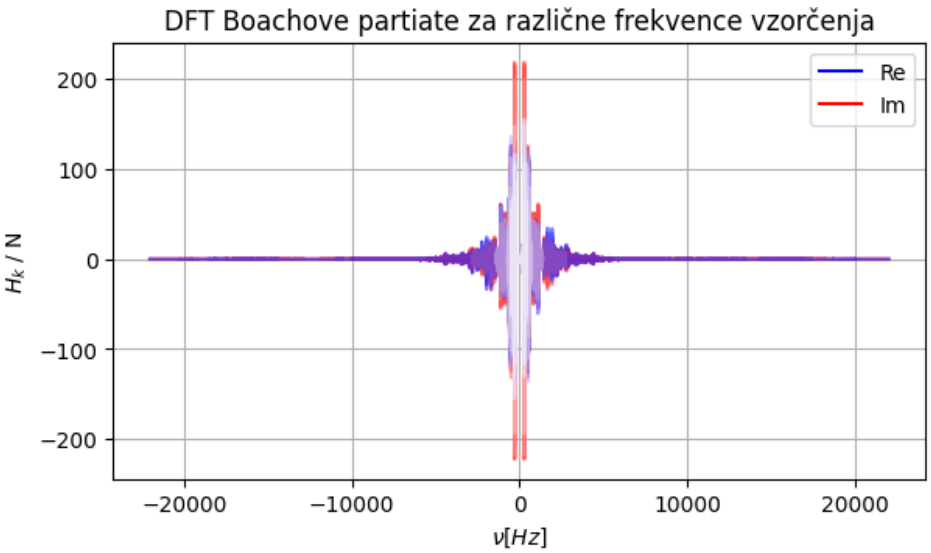

Slika 8: DFT Bachove partite.

Iz same DFT zaradi kompleksnosti signala ni najbolje razvidno, katere frekvence so najbolj zastopane. Bolj primerna reprezentacija zastopanosti frekvenc bi bila v spektralni moči. Ker je bila zastopanost frekvenc nad 5000 Hz zelo majhna, sem se odločil, da bom prikazal le frekvence do 5000 Hz. Spodnji graf prikazuje spektralno moč Bachove partite:

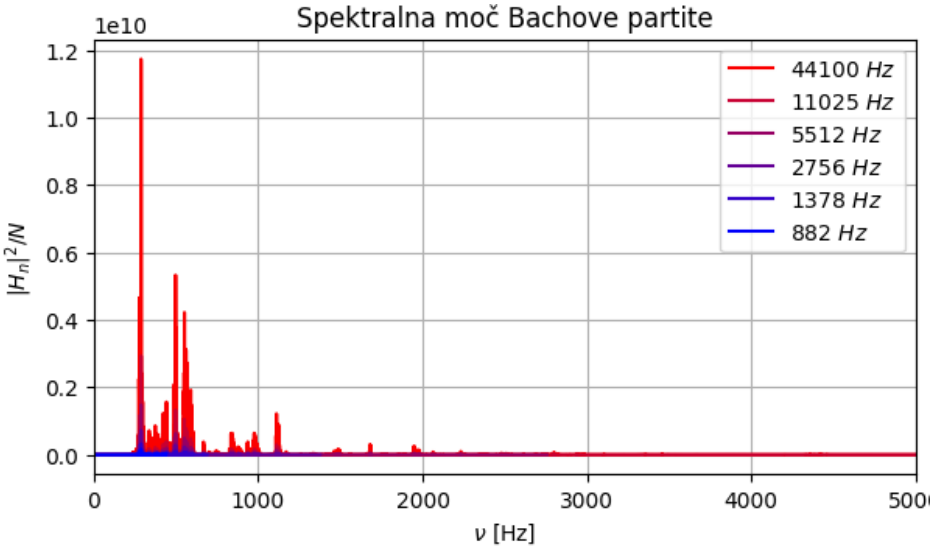

Slika 9: Spektralna moč Bachove partite.

Na zgornjem grafu sem delil$|H_n|^2$ z N, ampak se zdi kot da to ni najbolj

prav, saj se zdijo razlike med različnimi vzorčenji prevelike. Prav tako se mi zdi malce čudno, da je vrednost pri nižjih frekvencah večja za vzorčenja z večjo frekvenco vzorčenja, ko pa bi pričakoval, da se bodo pri manjših frekvencah vzorčenja frekvence nad Nyquistovo frekvenco 'prezrcalile' v interval $[-f_c, f_c]$, kar bi si predstavljal da bi se odražalo v večji moči znotraj tega intervala.

Za grafe spektralnih moči sem namesto prej omenjenih funkcij uporabil vgrajeno funkcijo `np.fft.fft(x)`, saj je imel računalnik premalo pomnilnika za obdelavo podatkov, vzorčenih s frekvenco 44.100 Hz. Pri uporabi funkcije DFT_simple bi obdelava signala trajala več kot 5 ur.

Signali iz vaje *Akustični resonator* in glasbil

Graf spektralne moči sem naredil tudi za signale iz vaje pri fizikalnem praktikumu in kitare ter glasbenih vilic. Z analizo posnetkov na spletni učilnici sem dobil naslednja grafa:

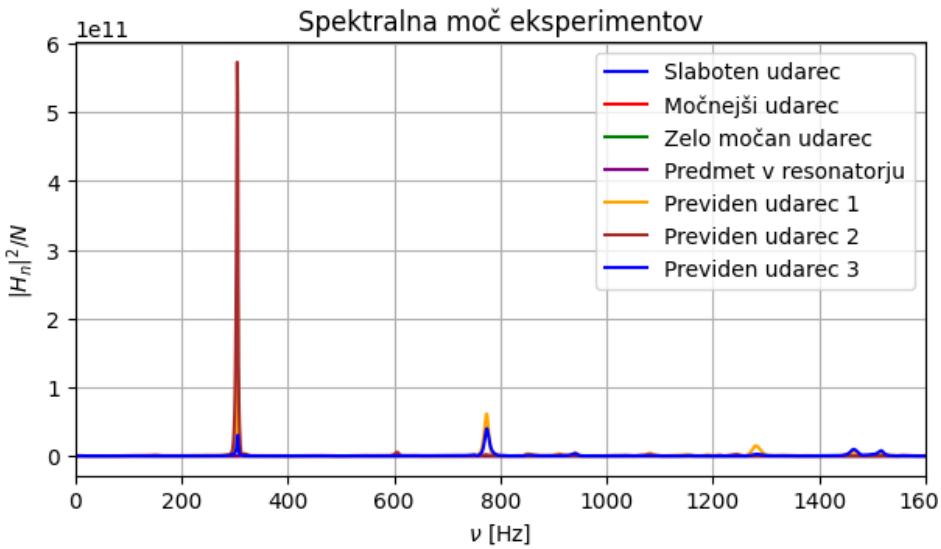

Slika 10: Spektralna moč signalov iz vaje *Akustični resonator*.

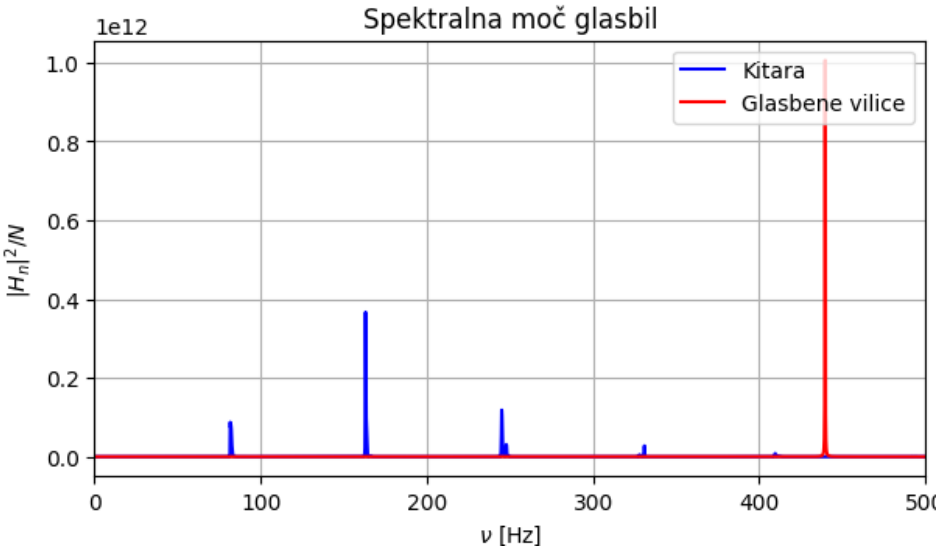

Slika 11: Spektralna moč kitare in glasbenih vilic.

Na zadnjem grafu se lepo razvidi, kako je zvok kitare sestavljen iz večih frekvenc, medtem ko je zvok glasbene vilice sestavljen iz ene same frekvence.