Numerična minimizacija

Razporeditev nabojev (in semafor)

Jakob Jerič, 28252025
Fakulteta za matematiko in fiziko, Univerza v Ljubljani
jj06142@student.uni-lj.si

22. oktober 2025

Naloga

1. **Thomsonov problem:** na prevodno kroglo nanesemo N enakih (klasičnih) nabojev. Kako se razmestijo po površini? Zahtevamo seveda minimum elektrostatične energije. Primerjaj učinkovitost in natančnost za različne minimizacijske metode, npr. Powellovo ali n-dimenzionalni simpleks (amebo oz. Nelder–Mead).

2. **Problem optimalne vožnje skozi semafor**, ki smo ga spoznali pri nalogi 1, lahko rešujemo tudi z numerično minimizacijo, če časovno skalo diskretiziramo.

   Lagrangianu
   $$\int \left(\frac{dv}{dt}\right)^2 dt - \lambda \int v\, dt$$
   lahko dodamo omejitev hitrosti v obliki členov $\exp\left[\beta(u - u_{\mathrm{lim}})\right]$, če hočemo (približno) zagotoviti $u \leq u_{\mathrm{lim}}$. Izpolnitev pogoja je toliko ostrejša, kolikor večji β vzamemo. Poskusiš lahko tudi druge omejitvene funkcije, na primer kakšno funkcijo s polom.

   Za iskanje Lagrangeovega multiplikatorja lahko uporabiš bisekcijo ali kakšno drugo vgrajeno metodo za iskanje ničel na funkciji
   $$l(\lambda) = \int v(\lambda, t)\, dt,$$
   kjer je $v(\lambda, t)$ rezultat minimizacije pri izbranem λ. V tem primeru je enakost izpolnjena eksaktno.

Uvod

Namen naloge je s pomočjo različnih metod numerične minimizacije poiskati minimum določene funkcije - npr. porazdelitev nabojev, ki se na površini telesa razporedijo tako, da je skupna elektrostatična energija sistema najmanjša ali pa minimizacija funkcionala iz prve naloge ($\int a^2 dt$). Problem razporeditve nabojev na omejeni površini imenujemo Thomsonov problem. Za majhno število nabojev obstajajo znane analitične rešitve, za večje sisteme pa moramo uporabiti numerične metode.

V nalogi sem med seboj primerjal tri različne metode minimizacije: Nelder–Meadovo metodo, Powellovo metodo in metodo konjugiranih gradientov (CG).

Nelder–Meadova metoda (tudi *simpleksna metoda*) je ena izmed najpreprostejših metod za minimizacijo funkcij brez uporabe odvodov. Temelji na geometrijskem postopku, pri katerem se v prostoru spremenljivk oblikuje telo, imenovano *simpleks* (v d-dimenzionalnem prostoru ima $d + 1$ oglišč). Vrednosti funkcije se izračunajo v vseh ogliščih, nato pa se simpleks postopno premika, razteza, krči ali zrcali glede na to, kje je funkcija manjša. Na ta način se simpleks prilagaja obliki površine funkcije in se sčasoma približuje območju z najmanjšo vrednostjo. Metoda je intuitivna in uporabna pri problemih, kjer odvod funkcije ni znan ali ga je težko izračunati.

Powellova metoda prav tako ne uporablja odvodov, vendar išče minimum z zaporednim minimiziranjem funkcije vzdolž različnih smeri v prostoru spremenljivk. Na začetku se izbere niz osnovnih smeri, nato pa metoda postopoma izvaja enodimenzionalne minimizacije vzdolž teh smeri. Po vsakem ciklu se smeri posodobijo, da bolje opisujejo lokalno obliko funkcije. Powellova metoda torej kombinira več enostavnih minimizacij vzdolž črt v postopku, ki omogoča postopno približevanje minimumu funkcije.

Metoda konjugiranih gradientov (CG) pa uporablja informacije o gradientu funkcije, torej o smeri njenega največjega naraščanja. Pri tej metodi se koraki izvajajo v smereh, ki so med seboj *konjugirane*, kar pomeni, da vsak nov korak popravlja napako v smeri, ki ni odvisna od prejšnjih. S tem se izognemo vračanju v iste smeri, kar omogoča bolj usmerjeno premikanje proti minimumu. Metoda temelji na postopnem iskanju optimalne kombinacije gradientov in je še posebej uporabna pri gladkih funkcijah, kjer lahko izračunamo ali ocenimo odvode.

Thomsonov problem

Thomsonov problem opisuje, kako se enaki električni naboji porazdelijo po površini prevodne krogle, če med njimi deluje le Coulombova sila. Vsak naboj se skuša čim bolj oddaljiti od drugih, zato se sistem uravnoteži v konfiguraciji, ki ima najmanjšo skupno elektrostatično energijo. Matematično to lahko zapišemo kot iskanje minimuma funkcije

$$E = \sum_{i<j} \frac{1}{|\vec{r}_i - \vec{r}_j|},$$

kjer so $\vec{r}_i$ vektorji položajev posameznih nabojev na površini krogle, vsi z enako velikostjo $|\vec{r}_i| = 1$.

Ker naboji ne smejo zapustiti površine, je treba po vsakem koraku optimizacije njihove položaje projicirati nazaj na kroglo. To pomeni, da vsak vektor $\vec{r}_i$ delimo z njegovo normo:

$$\vec{r}_i \longleftarrow \frac{\vec{r}_i}{|\vec{r}_i|}.$$

Tako zagotovimo, da minimuma funkcije ne iščemo drugje kot na površini sfere.

Za različno število nabojev (N) lahko vidimo razporeditve na spodnjih slikah:

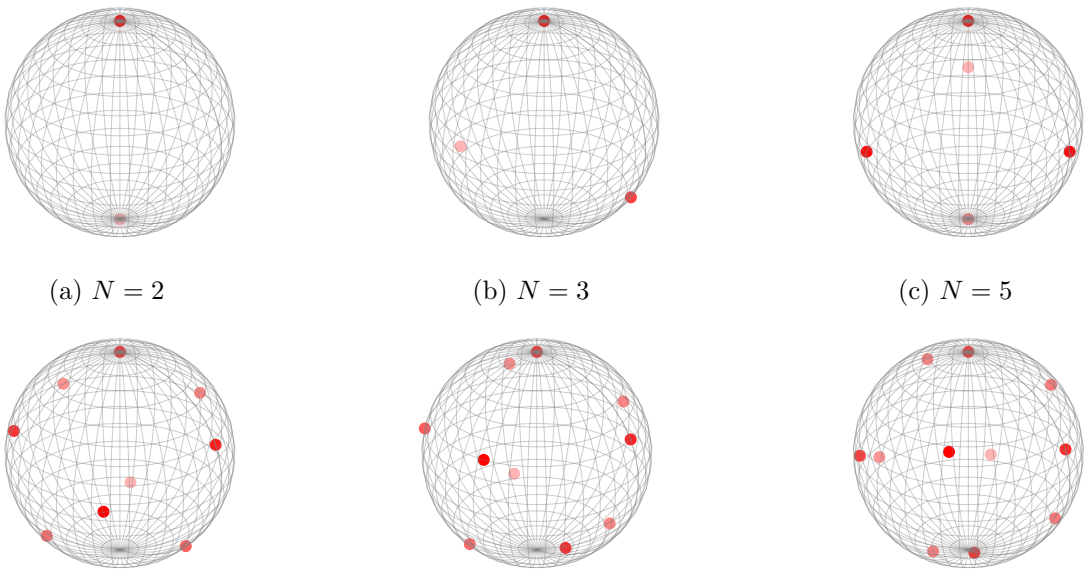

(a) $N = 2$ (b) $N = 3$ (c) $N = 5$

(d) $N = 9$ (e) $N = 10$ (f) $N = 11$

Slika 1: Razporeditev nabojev za različne vrednosti N.

Na primeru krogle sem tudi primerjal učinkovitost vseh 3 uporabljenih metod minimizacije. Za različne vrednosti N sem izmeril čas izvajanja, število klicev izračuna energije, porabo delovnega pomnilnika in izračunan minimum energije. Rezultate lahko vidimo na grafu na naslednji strani.

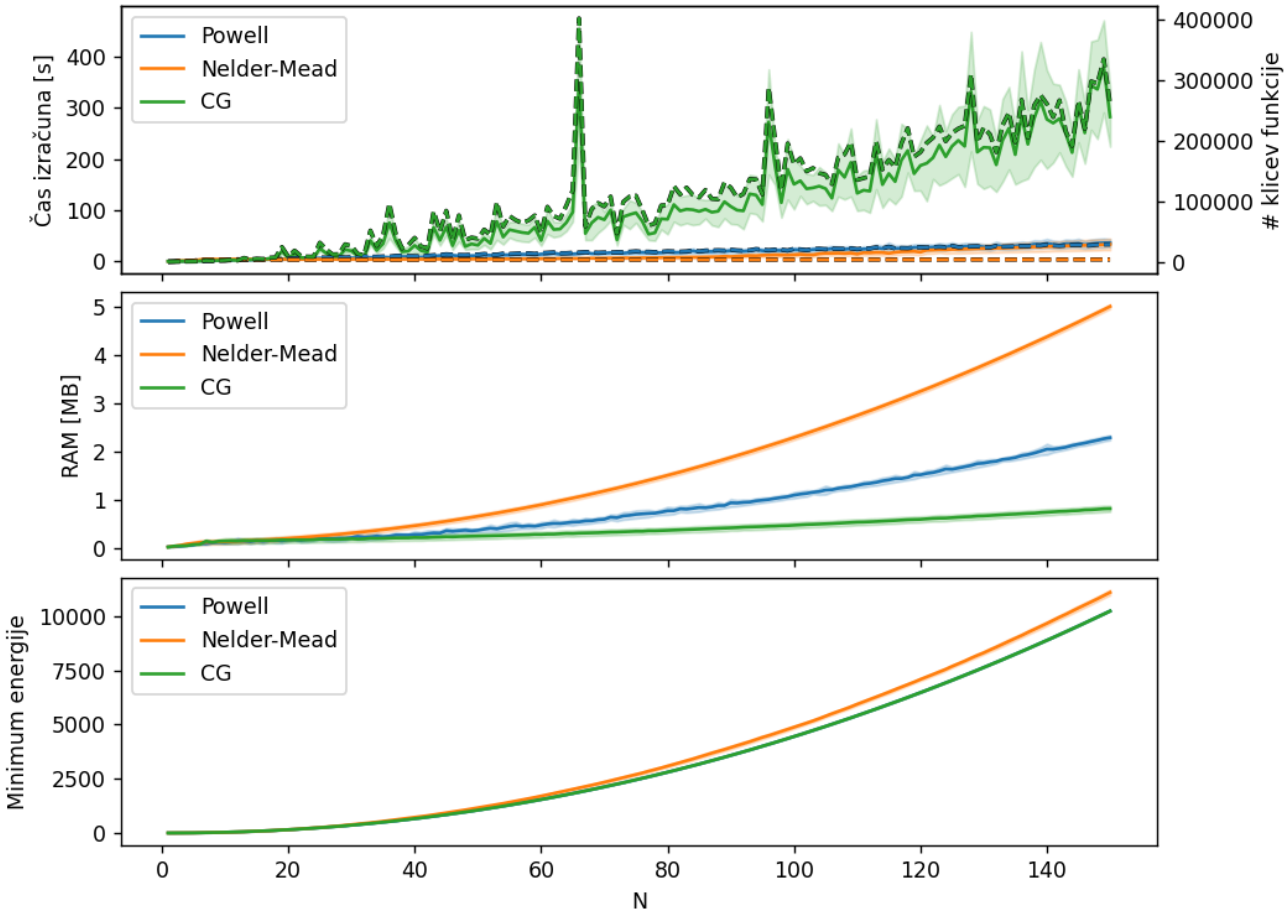

Slika 2: Primerjava učinkovitosti metod minimizacije za Thomsonov problem na krogli.

Iz grafa je razvidno, da je metoda CG med vsemi najbolj zamudna, a za svoje delovanje potrebuje najmanj delovnega pomnilnika. Opazimo tudi, da metoda Nelder-Mead ni našla tako nizkih minimumov kot ostali dve metodi, kar kaže na njeno manjšo natančnost. Iz zgornjega grafa lahko opazimo tudi, da je pri metodah Powell in CG čas izvajanja močno povezan s številom klicev izračuna energije - korelacijski koeficient med tema dvema količinama je namreč kar $r \approx 0.99$. To pomeni, da večina časovne zahtevnosti pri teh dveh metodah izvira iz izračuna energije, medtem ko je ta koeficient za metodo Nelder-Mead precej manjši ($r \approx 0.44$), kar kaže, da je pri tej metodi večji delež časa porabljen za druge operacije.

Druge ploskve

Namesto da smo v Thomsonovem problemu naboje razporedili na površino krogle, lahko to storimo tudi na drugih ploskvah. Če želimo na primer poiskati optimalno razporeditev nabojev na površini kocke, lahko to storimo na podoben način kot pri krogli. Edina razlika je v tem, da v definiciji funkcije, ki jo minimiziramo sedaj ne projeciramo vektorjev $\vec{r}_i$ na kroglo, ampak na površino kocke. To storimo tako, da vsak vektor $\vec{r}_i = (x_i, y_i, z_i)$ delimo z največjo komponento njegove absolutne vrednosti:

$$\vec{r}_i \longleftarrow \frac{\vec{r}_i}{\max(|x_i|, |y_i|, |z_i|)}.$$

Na Sliki 3 na naslednji strani so prikazane razporeditve nabojev na površini kocke za različne vrednosti N.

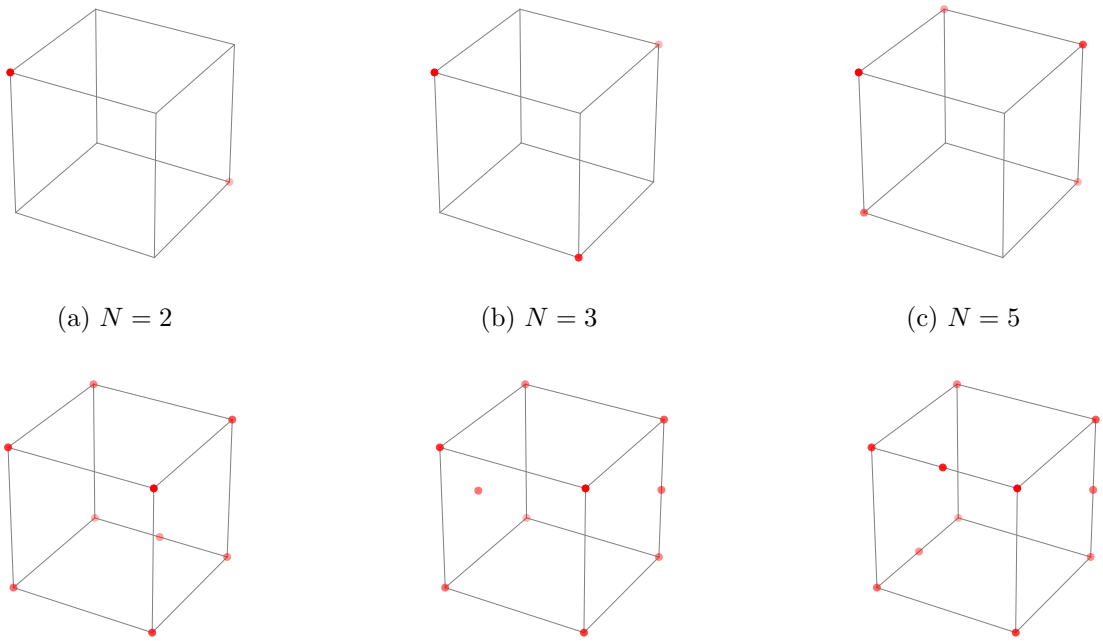

(a) $N = 2$ (b) $N = 3$ (c) $N = 5$

(d) $N = 9$ (e) $N = 10$ (f) $N = 11$

Slika 3: Razporeditev nabojev za različne vrednosti N na površini kocke.

Ker je funkcija, ki jo poskušamo minimizirati na kocki bolj žobnata"kot na krogli in ima tako več lokalnih minimumov, sa mi je kdaj zgodilo, da nisem našel zares globalnega mnimuma - npr. na Sliki 3e za $N = 10$ (namesto, da bi bil naboj na sredini čisto leve stranice, je na sredini zadnje leve ploskve). Najden lokalni minimum je bil odvisen od začetne naključne postavitve nabojev. V spodnji tabeli so predstavljeni primeri 5 najpogosteje najdenih energij za $N = 10$ z različnimi začetnimi postavitvami in za vsako od energij njena pogostost po 100 poskusih:

Vrednost	20.66	20.72	20.75	20.76	20.81
Pogostost	22%	33%	27%	3%	2%

Tabela 1: Pet najpogosteje najdenih minimumov na kocki za $N = 10$ in njihova relativna pogostost.

Rešitev na sliki 3e ustreza energiji $E \approx 20.75$. Podobnih težav v primeru nabojev razporejenih na sferi nisem imel in sem vedno našel globalni minimum.

Seveda lahko enak problem obravnavamo tudi v dveh dimenzijah, kjer projekcijo na disk dosežemo tako, da vse vektorje delimo z dolžino najdaljšega vektorja, projekcijo na kvadrat pa tako, da omejimo vsako komponento vsakega vektorja na interval $[-1, 1]$. Tudi v teh primerih mi ni vselej uspelo najti globalnega minimuma in je končna postavitev nabojev bila odvisna od začetne naključne postavitve, vendar za podrobnejšo analizo nisem imel časa. Rezultati minimizacije s `seed = 5` so predstavljeni na slikah na naslednji strani.

Čeprav minimalne energije niso povsem natančne in tako ne dobimo vedno porazdelitve naboja, ki ustreza globalnemu minimumu, so dobljene energije vseeno dokaj blizu pravim minimumom. Tako lahko naredimo smiselno primerjavo kako energija na različnih enako velikih ploskvah narašča s številom nabojev N. Graf $E(N)$ za različna telesa z enako površino (krogla, kocka, disk in kvadrat) je prikazan na Sliki 6. Opazimo, da energija hitreje narašča pri sferi in kocki, kot pri disku in kvadratu, kar je razumljivo, saj so naboji prisiljeni biti bližje skupaj zaradi pogoja, da imajo vse ploskve enako površino.

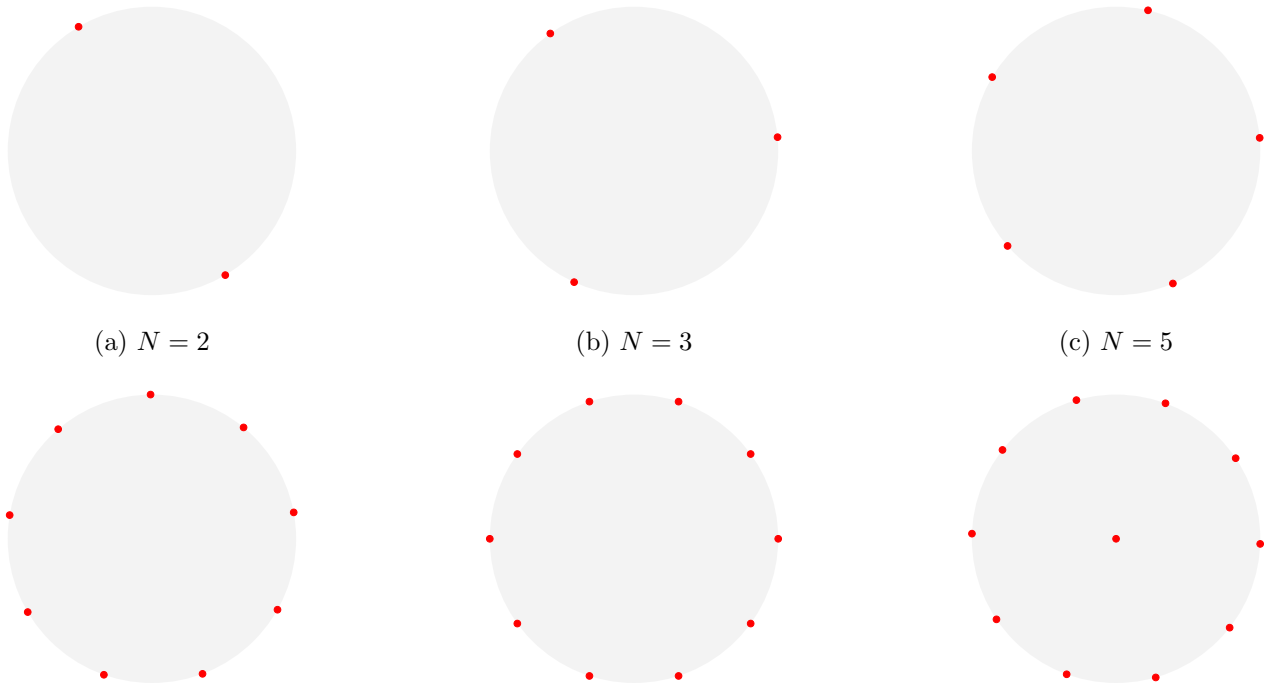

(a) $N = 2$ (b) $N = 3$ (c) $N = 5$

(d) $N = 9$ (e) $N = 10$ (f) $N = 11$

Slika 4: Razporeditev nabojev za različne vrednosti N na površini diska.

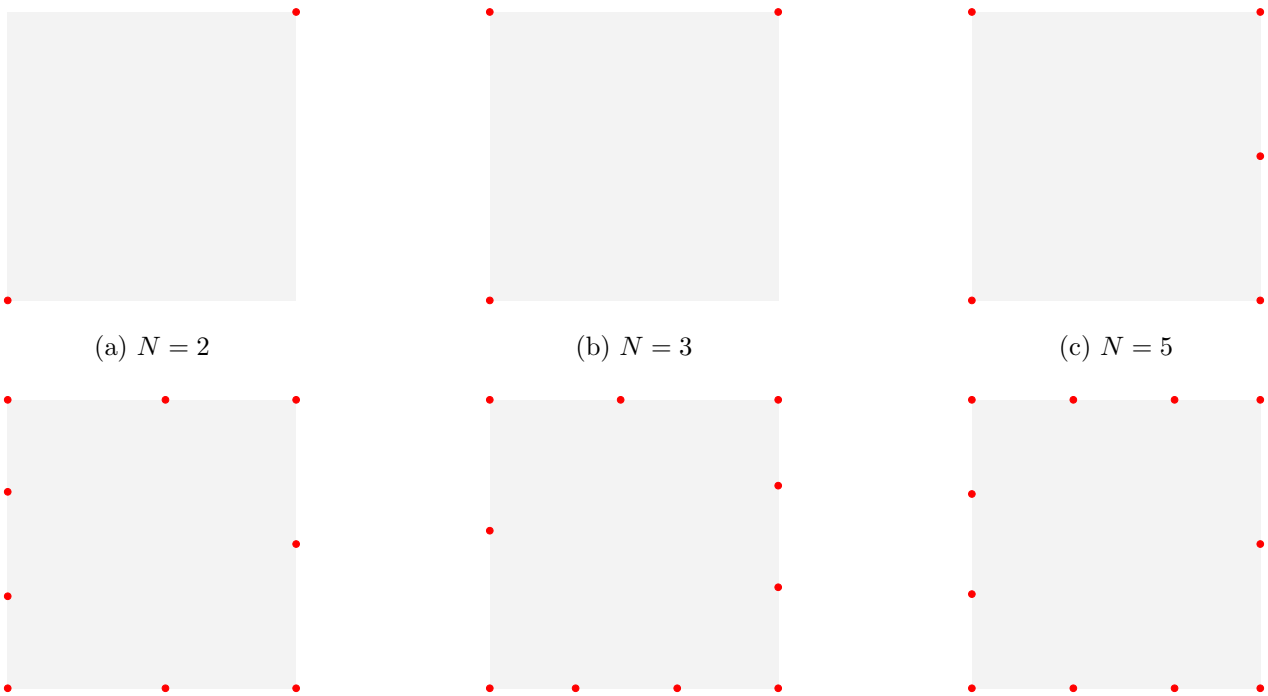

(a) $N = 2$ (b) $N = 3$ (c) $N = 5$

(d) $N = 9$ (e) $N = 10$ (f) $N = 11$

Slika 5: Razporeditev nabojev za različne vrednosti N na površini kvadra.

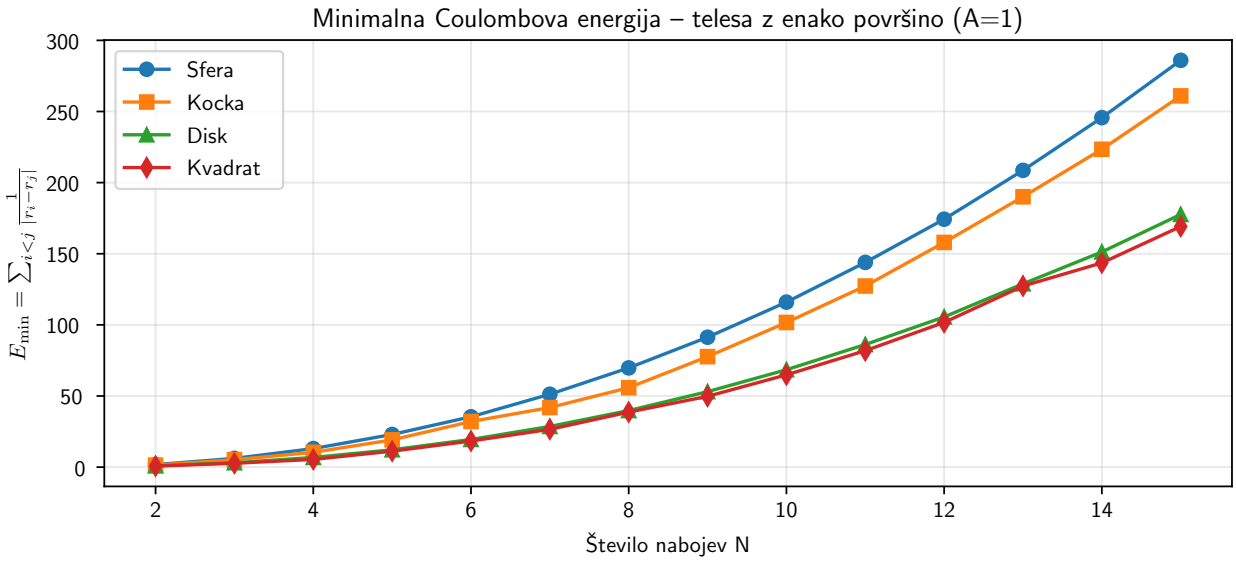

Slika 6: Minimalne energije N nabojev na različnih ploskvah z enako površino.

Optimalna vožnja skozi semafor

Namesto, da bi minimum funkcionala

$$\int \left(\frac{dv}{dt}\right)^2 dt - \lambda \int v\, dt$$

iskal z reševanjem Euler-Lagrangeovih enačb, lahko problem rešimo tudi z numerično minimizacijo. Ker nam funkcija `scipy.optimize.minimize` ne omogoča, da bi kot rešitev dobili funkcijo, ki je odvisna od λ, moramo celoten funkcional reševati za vnaprej predpisane vrednosti λ. Tako dobimo celo množico rešitev $v(t, \lambda)$. Da sem lahko našel pravo rešitev - torej tisto za katero velja $\int v(t, \lambda)dt = L$ - sem pogledal katera izmed dobljenih funkcij $v(t, \lambda)$ ima najmanjšo vrednost za $|\int v(t, \lambda)dt - L|$.

Sedaj, ko minimiziramo numerično, lahko tudi dokaj enostavno vsilimo omejitev hitrosti. To storimo tako, da v naš funkcional vsilimo kazenski člen, ki eksponentno narašča. Če želimo naprimer preprečiti nesmiselne negativne rešitve, ki smo jih dobili v prvi nalogi, hkrati pa hitrost omejiti navzgor z v_{lim}, lahko naš novi funkcional, ki ga minimiziramo zapišemo kot

$$J = \int \left(\frac{dv}{dt}\right)^2 dt - \lambda \int v\, dt + \int e^{-\beta v} + e^{\beta(v - v_{\text{lim}})} dt.$$

Večja β pomeni ostrejšo omejitev hitrosti. Grafi na naslednji strani (Slika 7) rezultate minimizacije za različne vrednosti β. S sivo so prikazane vse $v(t, \lambda)$, ki sem jih dobil z minimizacijo za različne vrednosti $\lambda \in [-15, 15]$, obarvane pa so poti, ki so v dani množici imele najmanjšo vrednost $|\int v(t, \lambda)dt - L|$. Večina obarvanih poti se zelo dobro ujema s pogojem $\int v(t, \lambda)dt = L$, vendar pa rešitve vseeno niso točne - odstopanja so v večini primerov od 1 do 3 %, v primeru ko pa imamo $\beta = 5$, $V_0 = 0$ in $L = 2$, pa se prevožena razdalja od L razlikuje za celo več kot 20 % (edina pravilna rešitev z dano omejitvijo hitrosti bi namreč bila, če bi v trenutku pospešili do $v = 2$ in tako vozili vse do konca).

Če bi se želeli izogniti iskanju večih optimalnih poti za različne vrednosti λ, bi lahko pogoj o prevoženi razdalji kar vključili v našo funkcijo, ki jo minimiziramo in kaznovali odstopanja:

$$J = \int \left(\frac{dv}{dt}\right)^2 dt + \alpha \left(\int v\, dt - L\right)^2 + \int e^{-\beta v} + e^{\beta(v - v_{\text{lim}})} dt.$$

Graf na Sliki 8 prikazuje rezultate minimizacije zgornjega izraza enakih začetnih hitrosti in hitrostnih omejitev kot Slika 7 za $\beta = 20$ in različne vrednosti α.

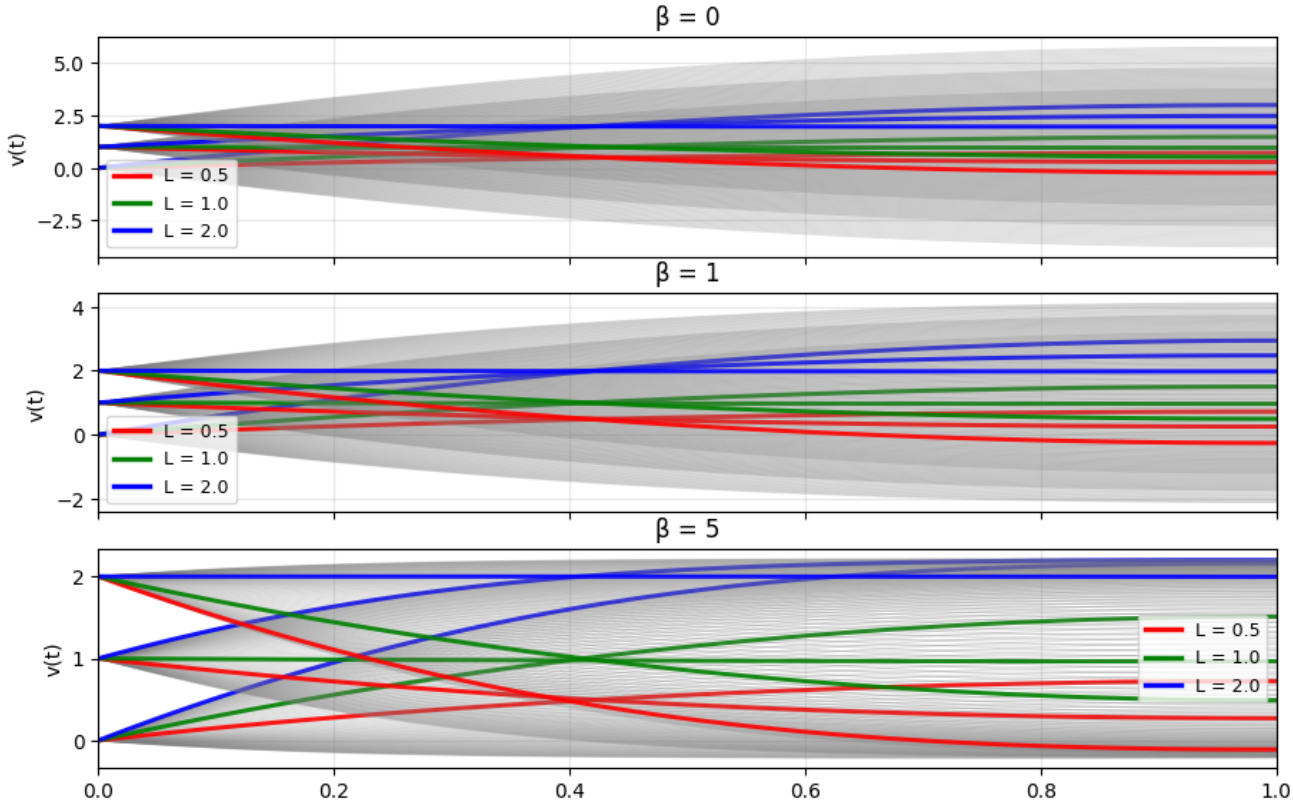

Slika 7: Optimalne poti $v(t)$ za različne vrednosti β.

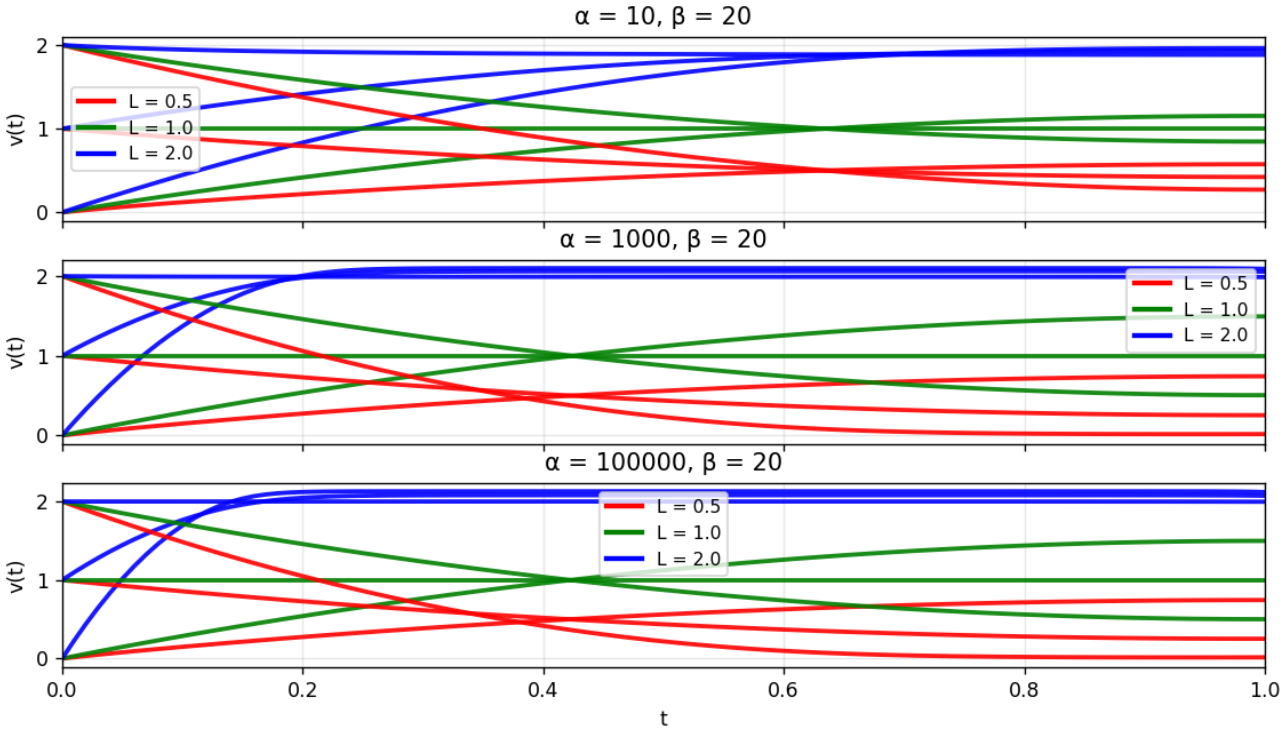

Slika 8: Optimalne poti $v(t)$ za različne vrednosti α in $\beta = 20$.

Tako smo lahko iz tega, da smo rabili generirati celo množico rešitev in potem iz njih izbrati najboljšo, prešli na to, da omjitev o prevoženi razdalji vsilimo kar v funkcijo, ki jo minimiziramo. Ne le, da smo tako morali izvesti le eno minimizacijo, temveč tudi dobljene rešitve sedaj veliko bolj

natančno izpolnjujejo pogoj $\int v(t)dt = L$ - pri $\alpha = 100000$ je največje odstopanje še vedno pri $V_0 = 0$, $L = 2$ in znaša manj kot 0,5 ‰.

Seveda pa vsaka dodatna omejitev poslabša našo "originalno"količino ki jo želimo minimiirati - v našem primeru je to $\int a^2 dt$. Graf na spodnji sliki prikazuje, kako se ta količina za "nemogoč"primer ko je $v_0 = 0$ in $L = 2$ spreminja z različnimi vrednostmi β in α. V primeru, ko nimamo nobenih omejitev, znaša $\int a^2 dt = 0$, a to je seveda primer, ko z avtomobilom ves čas stojimo na mestu.

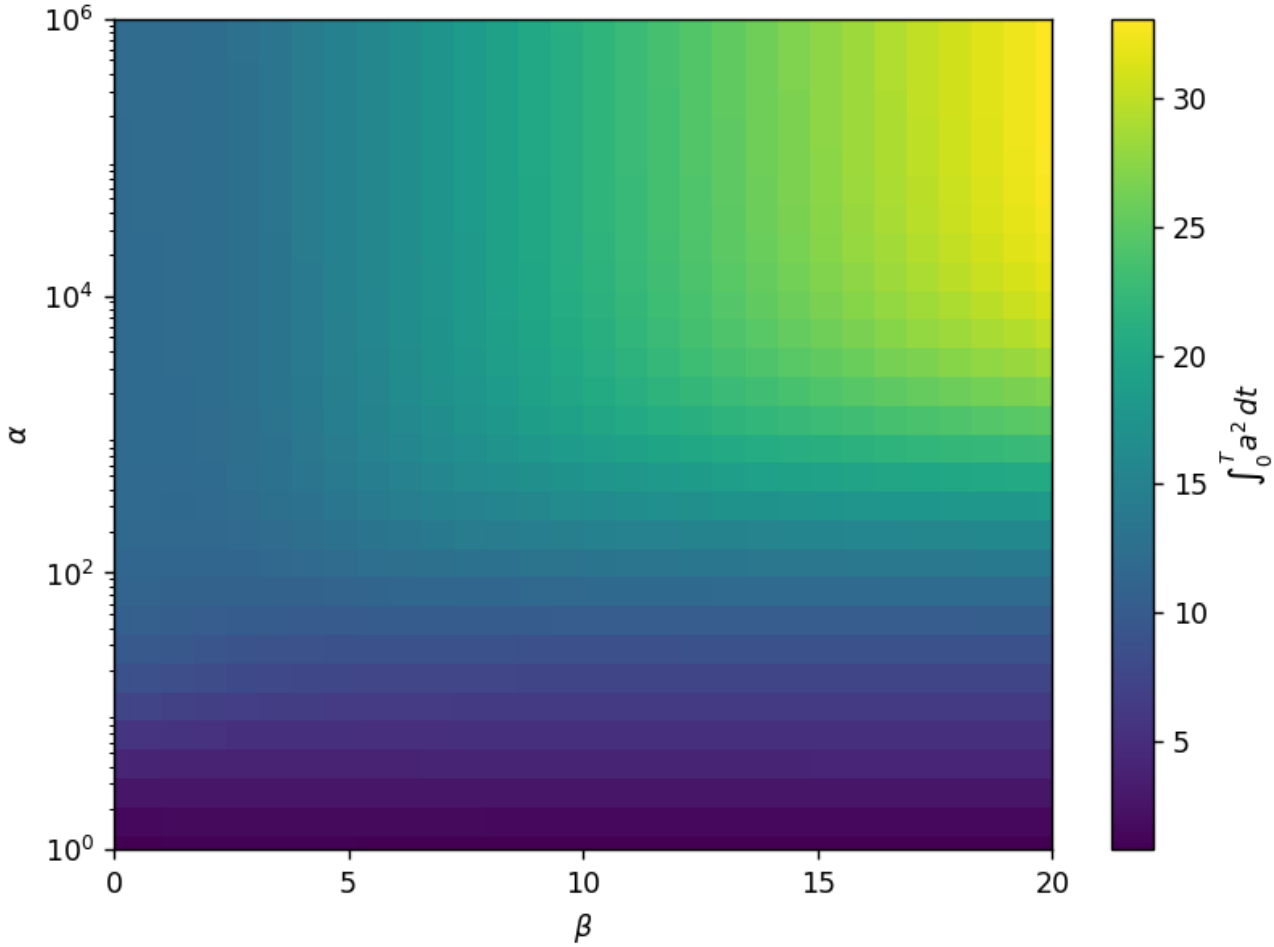

Slika 9: Vrednost $\int a^2 dt$ za različne vrednosti β in α v primeru $v_0 = 0$ in $L = 2$.