Stohastični populacijski modeli

Stohastični populacijski modeli

Jakob Jerič, 28252025
Fakulteta za matematiko in fiziko, Univerza v Ljubljani
jj06142@student.uni-lj.si

1. december 2025

Naloga

1. Napravi statistiko časov izumrtja za preprosti eksponentni model ($\beta = 1.0$/enota časa) za majhno ($N = 25$) in veliko ($N = 250$) populacijo. Ali je ta čas odvisen od velikosti časovnega koraka? Primerjaj z modelom, ki vključuje rojstva in smrti ($\beta_r = 4\beta$, $\beta_s = 5\beta$)!

2. Za zgornji model poišči matriko prehodov in z njo oceni čas izumrtja. Za preprost eksponentni model izumiranja lahko zapišeš enačbe za verjetnostno porazdelitev v odvisnosti od časa. Kako se efektivni odmik te porazdelitve spreminja s časom?

3. V stohastičnem modelu zajci–lisice določi povprečno življenjsko dobo sistema, če začnemo v ravnovesnem stanju. Za boljšo primerjavo med rezultati uporabi stacionarno stanje z 200 zajci in 50 lisicami ter razmerje rodnost/smrtnost 5/4 za zajce in obratno za lisice.

4. Stohastično simuliraj model epidemije iz 4. naloge z dodano možnostjo, da imuni postopoma spet postajajo dovzetni. Kakšna je statistika časov popolne eliminacije bolezni v odvisnosti od velikosti populacije in hitrosti izgubljanja imunosti?

Eksponentni model populacije

Želimo stohastično modelirati razvoj populacija, ki v najpreprostejšem modelu umira eksponentno. Diferencialna enačba, ki torej opisuje število posameznikov N v simulaciji je

$$\frac{dN}{dt} = -\beta N.$$

Kjer je β konstanta umiranja. Rešitev te enačbe je eksponentno padajoča funkcija. Če želimo enačbi napisati za diskreten korak v času bi lahko pisali $\Delta N = -\beta N \Delta t$, kjer je Δt časovni korak. Ker pa želimo, da je naša simulacija naključna, in da v vsakem koraku umre naključno število osebkov, to naredimo s pomočjo generatorja naključnih števil, ki so porazdeljena po Poissonovi porazdelitvi s povprečjem $\beta N \Delta t$. Sprememba števila posameznikov tako v vsakem koraku izgleda kot

$$\Delta N \sim \text{Poisson}\big(\beta\, N\, \Delta t\big).$$

Spodnja grafa prikazujeta kako izgleda 1000 stohastičnih simulacij in njihovo povprečje ter analitična rešitev, ki modelirajo eksponentno umiranje populacije z različnim začetnim številom N_0.

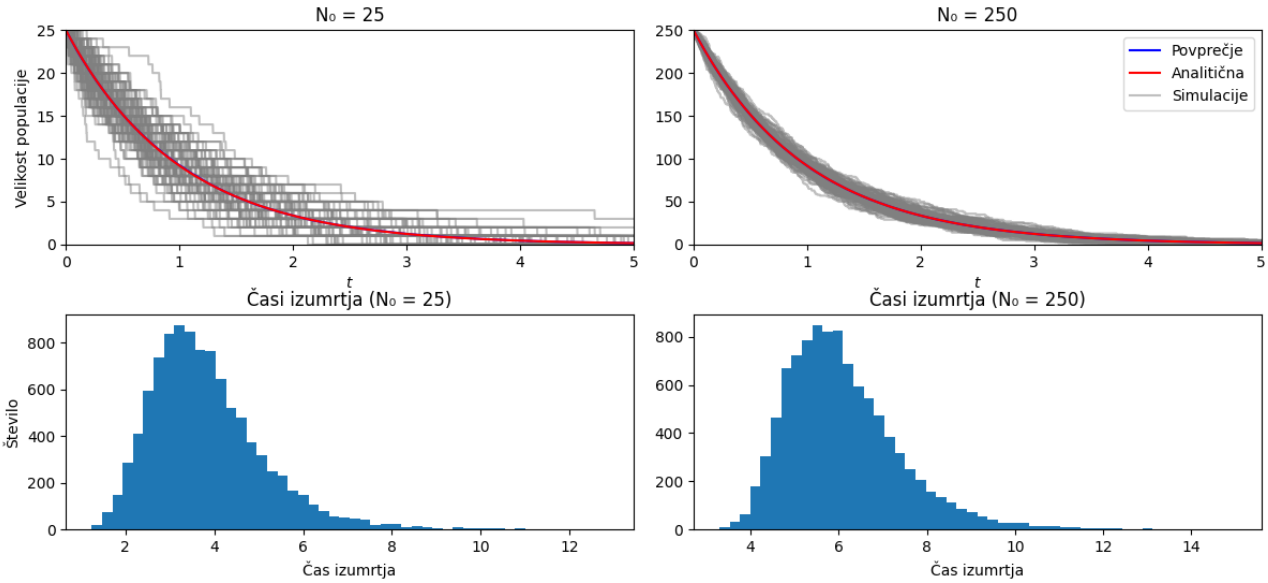

Slika 1

Bolj kot časovni potek števila posameznikov nas zanima statistika časov izumrtja populacije. Populacija izumre, ko število posameznikov pade na nič. Graf na naslednji strani prikazuje histogram časov izumrtja populacije za različne začetne velikosti populacije. Kot pričakovano opazimo, da večja kot je začetna populacija, daljši je povprečni čas izumrtja. Vse populacije imajo tudi lepo Poissonovo porazdelitev. Iz spodnjega grafa lahko tudi na hitro, brez bolj zanesljivih analiz ocenimo, da z eksponentnim večanjem populacije povprečni čas izumrtja (črtkana črta), narašča približno linearno.

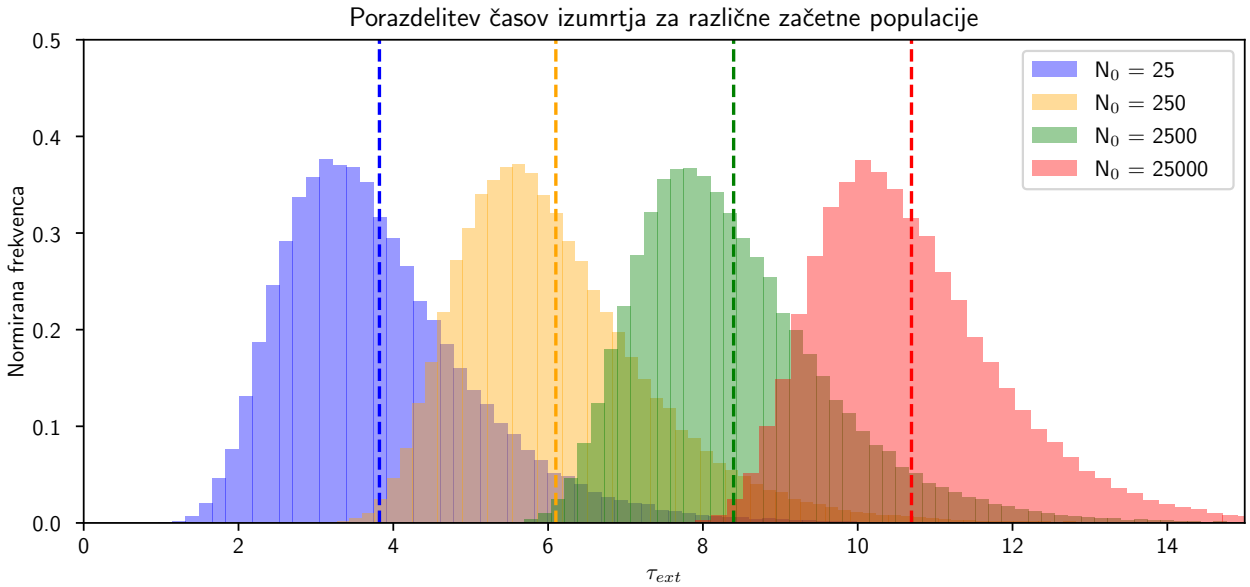

Slika 2

Pogledal sem tudi kakšen vpliv ima velikost časovnega koraka na statistiko časov izumrtja. Za zgoraj prikazane velikosti populacij, sem naredil simulacije pri različnih časovnih korakih. Spodnja grafa prikazujeta kako se povprečni čas izumrtja ter njegov drugi moment - zasenčeno območje - populacije spreminja z velikostjo časovnega koraka.

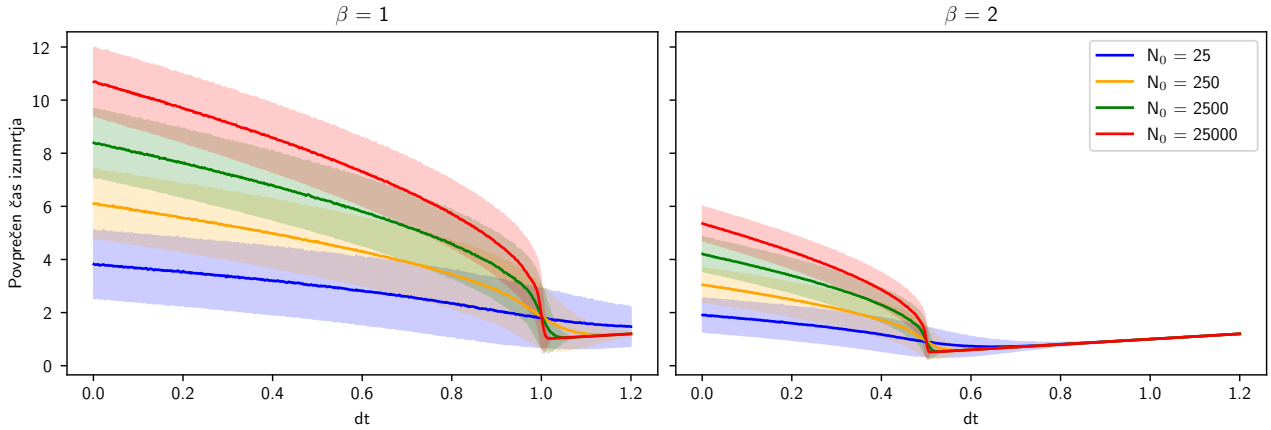

Slika 3

Opazimo, da z večanjem časovnega koraka, povprečni čas izumrtja pada. Ko pa je časovni korak enak kosntanti umiranja $1/\beta$, pa opazimo da so vsi povprečni časi izumrtja enaki - torej neodvisni od začetne velikosti populacije. Seveda pri tako velikih časovnih korakih simulacije niso več smiselne. Opazimo, da do tega pojava - da je čas izumiranja pri $\Delta t = 1/\beta$ enak za vse velikosti populacij - pride v obeh primerih $\beta = 1$ in $\beta = 2$.

Poleg preprostega modela, kjer imamo le eksponentno umiranje, lahko pogledamo tudi model, kjer

imamo eksponentna rojstva in umiranja. Ker želimo v povprečju enako obnašanje bomo nastavili konstanti rojstev in umiranj tako, da je $\beta_r = 4\beta$ in $\beta_s = 5\beta$, kjer je β konstanta iz prejšnjega modela, β_r je konstanta rojstev in β_s konstanta umiranj. Za vsak časovni korak lahko zdaj v stohastični diskretni sliki pišemo

$$\Delta N \sim \text{Poisson}\big(\beta_r\, N\, \Delta t\big) - \text{Poisson}\big(\beta_s\, N\, \Delta t\big).$$

Naivno bi pričakovali, da bodo zaradi enake analitične rešitve povprečni časi izumrtja enaki kot v prejšnjem primeru. Vendar pa opazimo, da so povprečni časi izumrtja v tem primeru nekoliko krajši. To je prikazano na spodnjem grafu.

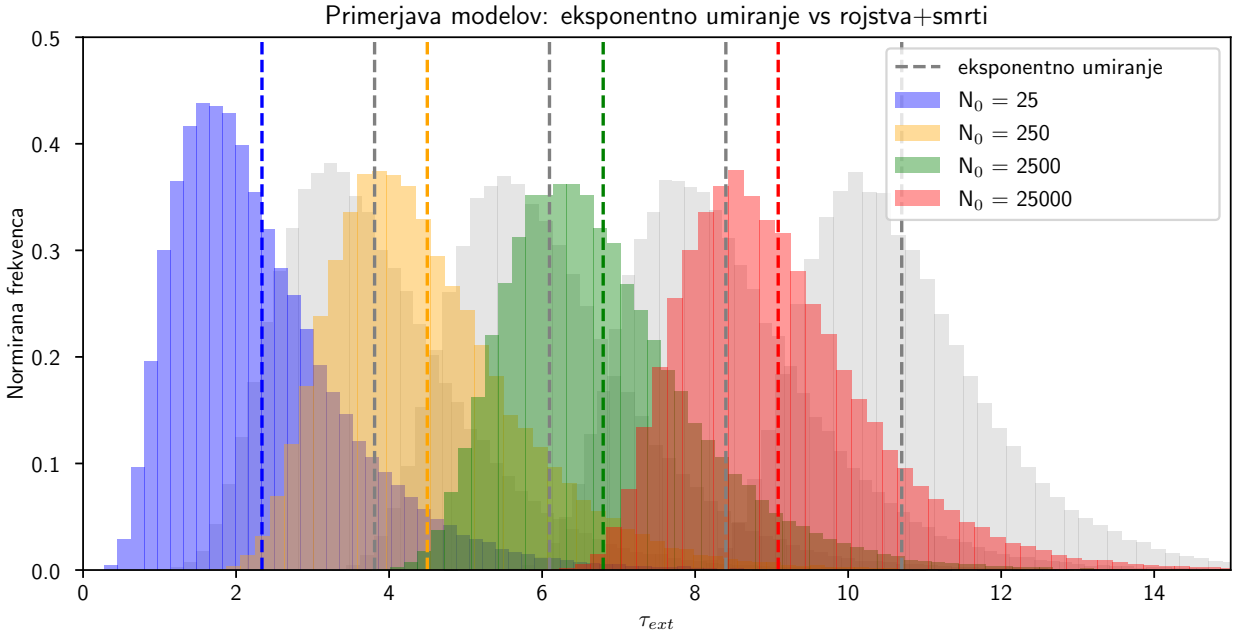

Slika 4

S sivo barvo so prikazane rešitve enostavnega modela eksponentnega umiranja z barvami pa modela, kjer imamo rojstva in smrti. Ponovno opazimo da eksponentno večje populacije živijo linearno dlje in da so časi izumrtja porazdeljeni Poissonovo za vse velikosti populacije

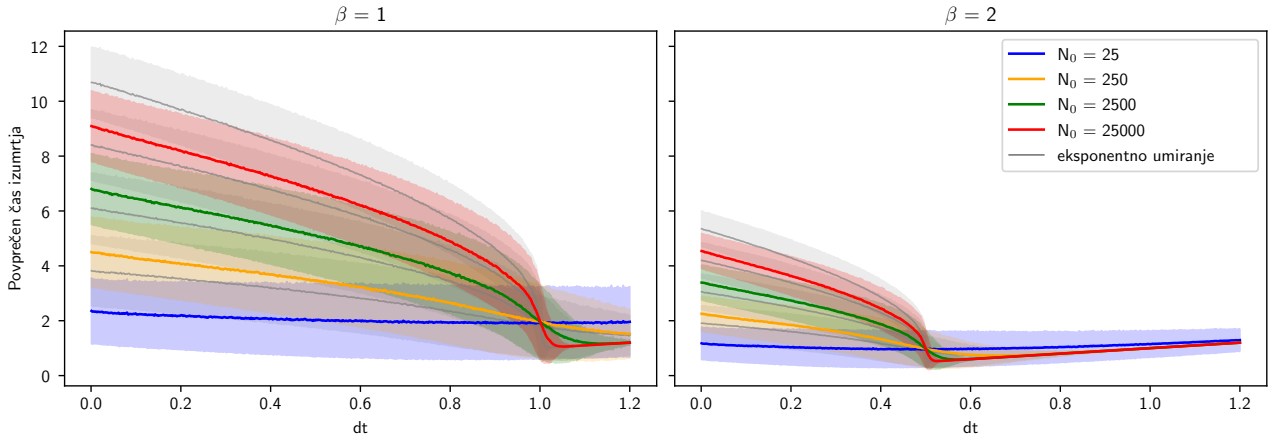

Slika 5

Odvisnost povprečnega časa izumrtja od časovnega koraka pa je podobna kot v prejšnjem primeru. Morda bi pričakovali, da z manjšanjem časovnega koraka, povprečni čas izumrtja narašča proti vre-

dnosti iz prejšnjega primera - saj prehajamo v čedalje bolj zvezno sliko, a bi se tudi tukaj zmotili. Sive črte enako kot v zgornjem grafu predstavljajo rešitve preprostega modela eksponentnega umiranja.

Opisanega problema se lahko poleg s simulacijami lotimo tudi s prehodno matriko. Če opazujemo vektor verjetnosti stanj $\vec{x}$, kjer je x_i verjetnost, da imamo v populaciji i osebkov, lahko zapišemo enačbo za časovni razvoj tega vektorja v diskretni obliki

$$\vec{x}(t + \Delta t) = M\vec{x}(t),$$

kjer je M prehodna matrika. Ker je časovni korak Δt dovolj majhen, je verjetnost, da bi v enem koraku umrla dva ali več osebkov, zanemarljiva (takšni dogodki so reda $(\Delta t)^2$). Zato lahko predpostavimo, da se v enem koraku populacija spremeni za največ eno enoto. V najpreprostejšem modelu, kjer imamo samo umiranje, lahko iz stanja i preidemo le v stanje i (nič se ne zgodi) ali v stanje $i - 1$ (umre en osebek). Za majhen Δt ima prehodna matrika zato tri-diagonalno obliko. Začetni del matrike lahko zapišemo kot

$$M_{\text{death}} \approx \begin{pmatrix} 1 & \beta\,1\,\Delta t & 0 & 0 & 0 & \cdots \\ 0 & 1-\beta\,1\,\Delta t & \beta\,2\,\Delta t & 0 & 0 & \cdots \\ 0 & 0 & 1-\beta\,2\,\Delta t & \beta\,3\,\Delta t & 0 & \cdots \\ 0 & 0 & 0 & 1-\beta\,3\,\Delta t & \beta\,4\,\Delta t & \cdots \\ \vdots & & & \ddots & \ddots & \ddots \end{pmatrix}.$$

Prva vrstica odraža, da je stanje 0 absorbirajoče: ko populacija enkrat doseže 0, tam tudi ostane. Nas torej zanima časovni razvoj vektorja verjetnosti, ki se začne v stanju z N_0 osebki. Spodnja grafa prikazujeta kako se komponente vektorja (x_i) - os x - spreminjajo s časom - os y.

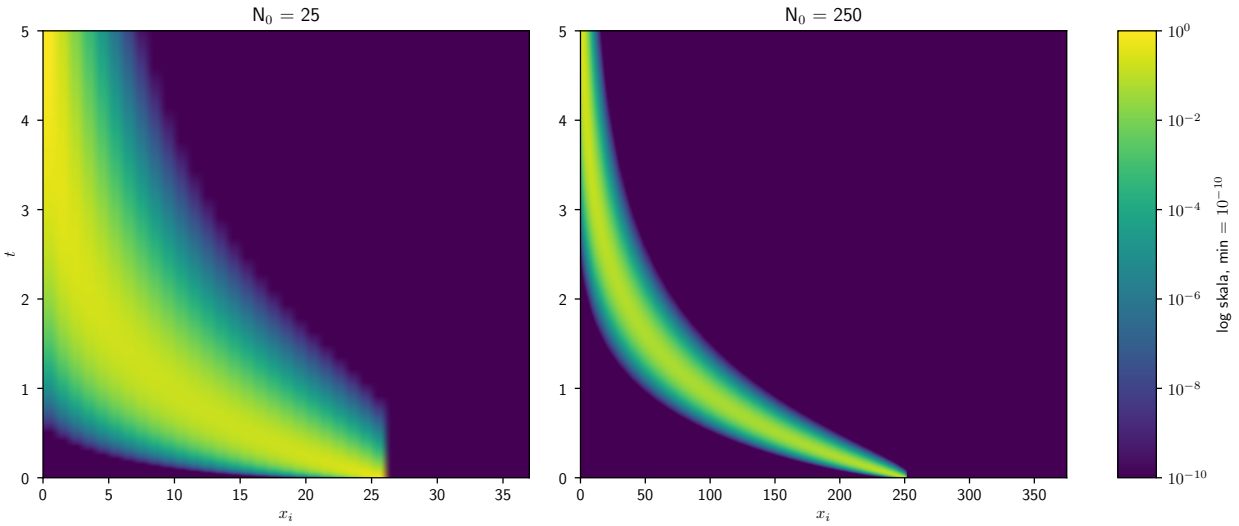

Slika 6

Pri zgornjem grafu je barvna skala logaritemska ter odrezana pri 10^{-10}, torej so verjetnosti za posamezno stanje dokaj majhne. Opazimo tudi, da imamo pri manjših populacjah večjo relativno raztrosenost po stanjih, kar je smiselno, saj so zaradi naključnosti manjše populacje težje relativno predvidljive.

Podoben postopek uporabimo pri modelu, kjer imamo hkrati rojstva in smrti. V tem primeru se lahko iz stanja i premaknemo v $i - 1$ (umre en osebek), v i (nič se ne zgodi) ali v $i + 1$ (rodi se en osebek). Tokrat je na nad-diagonali stopnja smrti β_s, na pod-diagonali pa stopnja rojstev β_r. Začetni del matrike je v tem primeru

$$M_{\text{birth–death}} \approx \begin{pmatrix} 1 & \beta_s\, 1\, \Delta t & 0 & 0 & 0 & \cdots \\ \beta_r\, 0\, \Delta t & 1-(\beta_r+\beta_s)\, 1\, \Delta t & \beta_s\, 2\, \Delta t & 0 & 0 & \cdots \\ 0 & \beta_r\, 1\, \Delta t & 1-(\beta_r+\beta_s)\, 2\, \Delta t & \beta_s\, 3\, \Delta t & 0 & \cdots \\ 0 & 0 & \beta_r\, 2\, \Delta t & 1-(\beta_r+\beta_s)\, 3\, \Delta t & \beta_s\, 4\, \Delta t & \cdots \\ \vdots & & & \ddots & \ddots & \ddots \end{pmatrix}.$$

Tudi tukaj je stanje 0 absorbirajoče, saj pri $i = 0$ ni ne rojstev ne smrti. Spodaj je prikazan enak graf še za model rojstev in smrti.

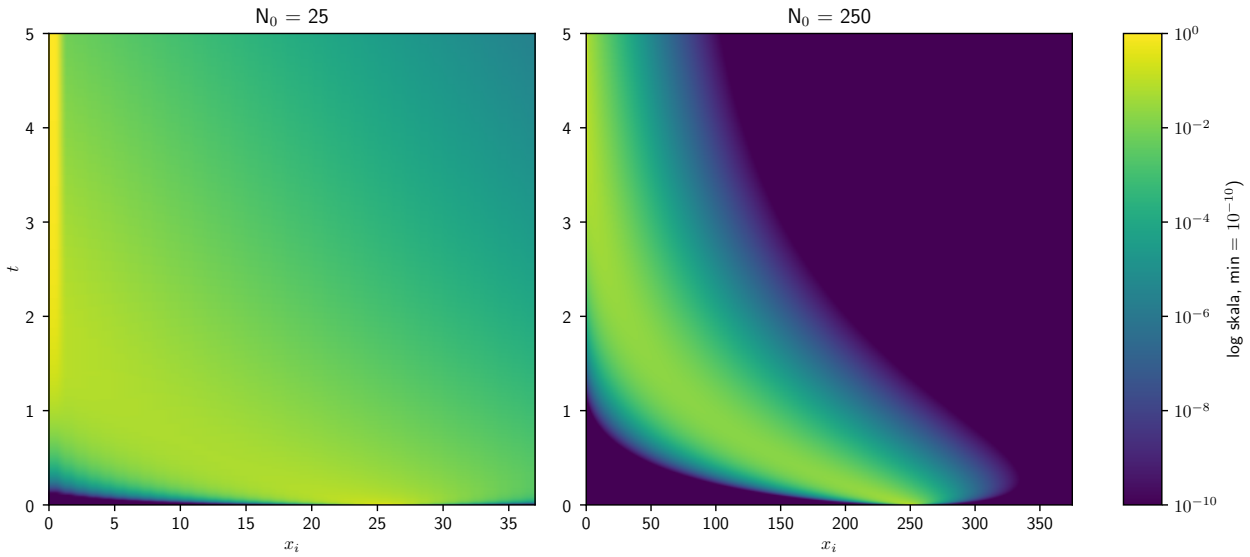

Slika 7

Opazimo da sta grafa dokaj podobna kot v prejšnjem primeru. Očitna je razlika, da je sedaj mogoče tudi stanje kjer je $i > N_0$, saj se lahko populacija tudi povečuje zaradi rojstev. Poleg tega opazimo tudi večjo razpršenost za obe velikosti populacij kot v preprostejšem modelu. Pri manjši populacij lahko slabo opazimo tudi, da je stanje $i = 0$ doseženo nekoliko hitreje kot v prejšnjem primeru. To nekako pojasni krajše čase izumrtja.

Tudi tukaj lahko pogledamo kako so porazdeljeni časi izumrtja za oba modela za obe velikosti začetnih populacij. Spodnji graf prikazuje kako se je v vsakem časovnem koraku povečala vrednost ničle komponente vektorja $\vec{x}$, ki predstavlja verjetnost, da je populacija izumrla. Ker je ta sprememba seveda odvisna od velikosti časvnega koraka, sem vrednosti normiral z največjo izmerjeno.

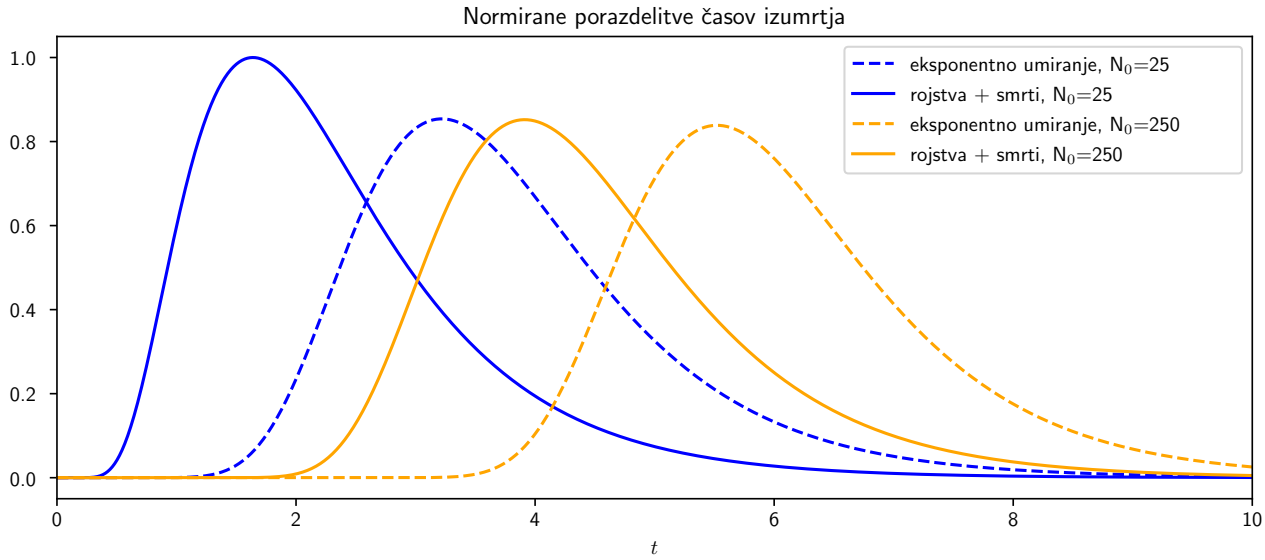

Slika 8

Oblike porazdelitev so praktično enake kot pri stohastičnih simulacijah, kar potrjuje pravilnost obeh pristopov.

Lotka-Volterra

Poleg preprostega rojevanja iin umiranja vrste lahko dodamo tudi razmerje med 2 vrstama - plenilec in plen. Enačbe za takšno vrsto odnosa smo izpeljali že v prejšnji nalogi. Takrat smo imeli le "efektivno" umiranje/razmnoževanje, zdaj, ko pa delamo stohastično moramo upoštevati dejansko stopnjo umiranja/razmnoževanja. V stohastičnem modelu Lotka-Volterra enačb imamo torej naslednje procese:

- Zajci se razmnožujejo z hitrostjo $\beta_{Zr} = 5\beta$,
- Zajci umirajo z hitrostjo $\beta_{Zs} = 4\beta$,
- Lisice se razmnožujejo z hitrostjo $\beta_{Lr} = 4\beta$,
- Lisice umirajo z hitrostjo $\beta_{Ls} = 5\beta$,
- Zajci umirajo zaradi plenjenja z hitrostjo $\gamma_Z = \frac{\beta}{50}$,
- Lisice se množijo zaradi plenjenja s hitrostijo $\gamma_L = \frac{\beta}{200}$.

Obe enačbi lahko tako napišemo kot

$$\Delta Z \sim \text{Poisson}\big(\beta_{Zr}\, Z\, \Delta t\big) - \text{Poisson}\big(\beta_{Zs}\, Z\, \Delta t\big) - \text{Poisson}\big(\gamma_Z\, Z\, L\, \Delta t\big),$$
$$\Delta L \sim \text{Poisson}\big(\beta_{Lr}\, L\, \Delta t\big) - \text{Poisson}\big(\beta_{Ls}\, L\, \Delta t\big) + \text{Poisson}\big(\gamma_L\, Z\, L\, \Delta t\big).$$

Graf na naslednji strani prikazuje kako se razvija deterministična, zvezna simulacija iz četrte naloge za različne začetne pogoje in za vsak začetni pogoj po ena stohastična simulacija. Ker smo tako nastavili γ_Z in γ_L, je stacionarna točka na diagramu okoli $Z = 200$ in $L = 50$. Ta je ponazorjena z modro piko, saj se pri determinističnih simulaciji ne dogaja nič - imamo stacionarno stanje. Če pa želimo model simulirati stohastično, pa opazimo, da hitro zaidemo izven stacionarnega stanja in obidemo precejšen delež faznega diagrama.

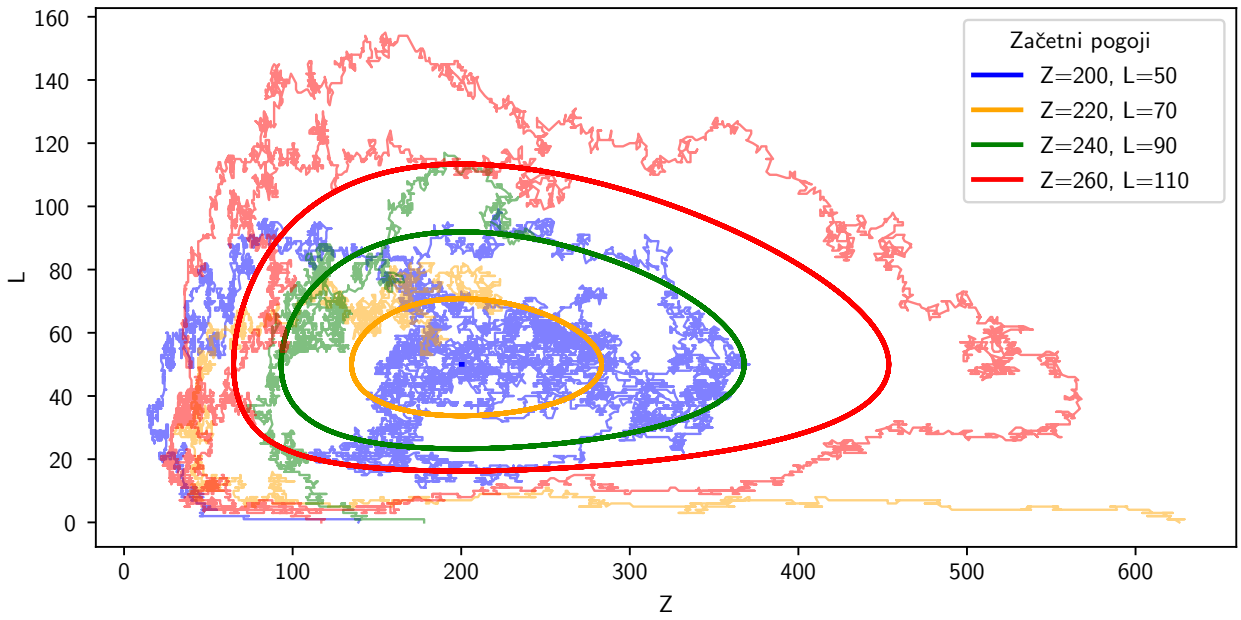

Slika 9

Ponovno nas zanima čas izumrtja sistema. Ker se zajci v odsotnosti lisic brez ovire razmnožujejo, definiram izumrtje sistema kot izumrtje lisic. Za enake začetne pogoje kot na zgornjem diagramu sem naredil 10000 stohastičnih simulacij in zbral statistiko časov izumrtja. Njihova porazdelitev je prikazana na spodnjem grafu.

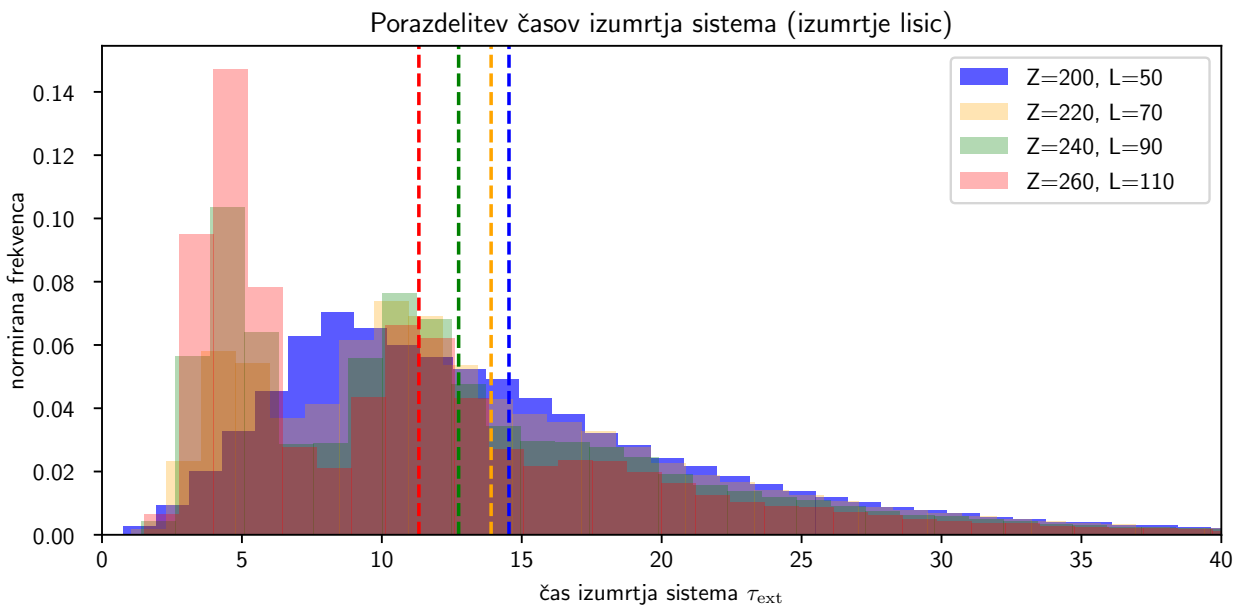

Slika 10

Kot pričakovano imajo sistemi, ki so bili izbrani bliže stacionarni točki v povprečju daljši povprečni čas izumrtja. Zanimivo je tudi dejstvo, da se pri sistemih, kjer je bilo začetno stanje izmaknjeno iz stacionarne točke pojavi nekakšen vrh bolj na začetku in tudi bolj kot je sistem izmaknjen iz stacionarnega stanja bolj izrazit je ta vrh. To je verjetno posledica, da ima sistem večjo verjetnost izumrtja, ko smo na točkah v faznem diagramu, kjer je število lisic relativno majhno, v te točke pa prihajamo periodično - kot smo izvedeli v četrti nalogi.

Epidemija z izgubo imunosti

Enako kot v pejšnji nalogi želimo le enačbe epidemije, ki smo jo že obravnavali v zveznem primeru

$$\begin{aligned}\frac{dD}{dt} &= -R_0 DB + cB(t-\tau_a),\\ \frac{dB}{dt} &= R_0 DB - B,\\ \frac{dI}{dt} &= B - cB(t-\tau_a),\end{aligned}$$

kjer je D delež dovzetnih, B delež bolnih, I delež imunih posameznikov v populaciji, c pa "verjetnost"da po času τ_a imunost izgine. V stohastični verziji pa lahko zapišemo spremembe v vsakem časovnem koraku kot

$$\begin{aligned}\Delta D &\sim \text{Poisson}\big(R_0 DB\Delta t\big) + \text{Poisson}\big(cB(t-\tau_a)\Delta t\big),\\ \Delta B &\sim \text{Poisson}\big(R_0 DB\Delta t\big) - \text{Poisson}\big(B\Delta t\big),\\ \Delta I &\sim \text{Poisson}\big(B\Delta t\big) - \text{Poisson}\big(cB(t-\tau_a)\Delta t\big).\end{aligned}$$

Tukaj seveda D, B in I ne predstavljajo več deležev populacije, ampak število posameznikov v populaciji. Spodnji grafi prikazujejo kako se za različni vrednosti parametra c in R_0 spreminja delež bolnih za zvezen model in za stohastične simulacije treh različnih velikosti populacij.

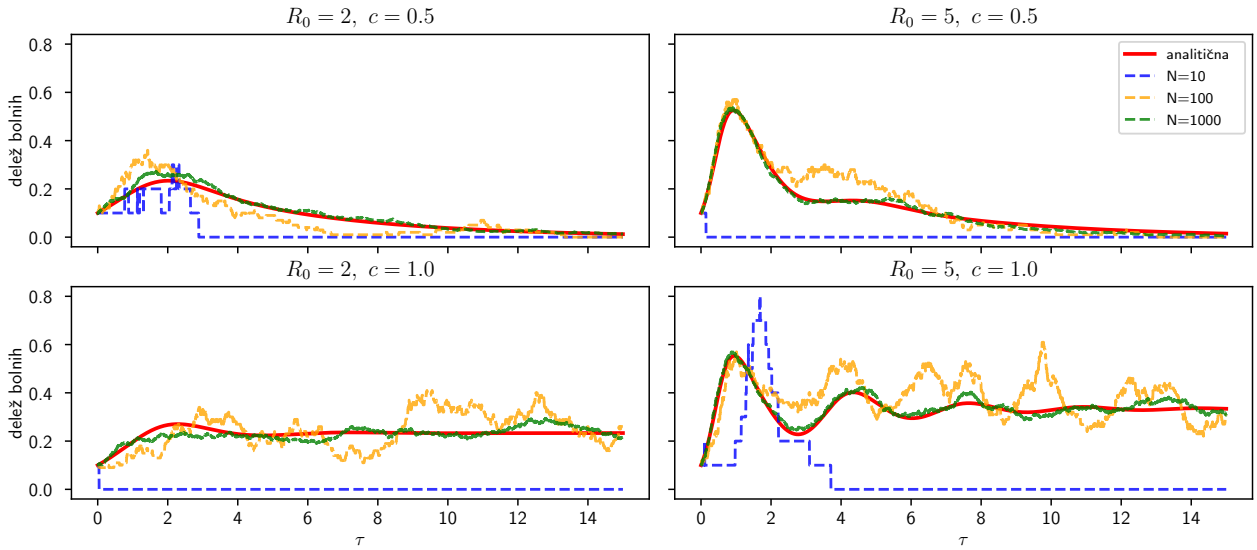

Vidimo, da večja kot je populacija, bolj se stohastični model približa zveznemu. Prav tako opazimo, da pri $c = 1$ dobimo stacionarno stanje, kjer $B > 0$, kar pomeni, da se epidemija v zveznem modelu sploh nikoli ne konča.

Zanima nas torej kako je čas konca epidemije - $B = 0$ - odvisen od velikosti populacije in parametra časa τ_a. Grafi na naslednji strani prikazujejo prav to odvisnost. opazimo, da se čas izginotja epidemije s številom populacije veča, kar je smiselno, saj večja populacija bolj sledi zvezni simulaciji, kjer se vrednost B v resnici nikoli ne doseže prav 0. Opazimo tudi, da se najprej z večanjem parametra τ_a čas izginotja epidemije povečuje, nato pa spet zmanjšuje. Parameter τ_a namreč določa kako hitro imunost izgine in določa razdaljo med vrhovi epidemije - graf zgoraj za $c = 1$ in $R_0 = 5$. Ti vrhovi so lahko bolj ali manj opazni - odvisno od parametrov. Če povečujemo τ_a na začetku tako epidemijo razvlečemo na dalj šasa in daljša razdalja med vrhovi pomeni daljši čas do konca epidemije. Ko pa je τ_a veliko večji od trajanja epidemije pa dobimo šezone"bolezni, kot smo že ugotovili v četrti nalogi. Zaradi stohastičnosti lahko v teh primerih pride, da število bolnih pade prav na 0 in epidemija se konča prej
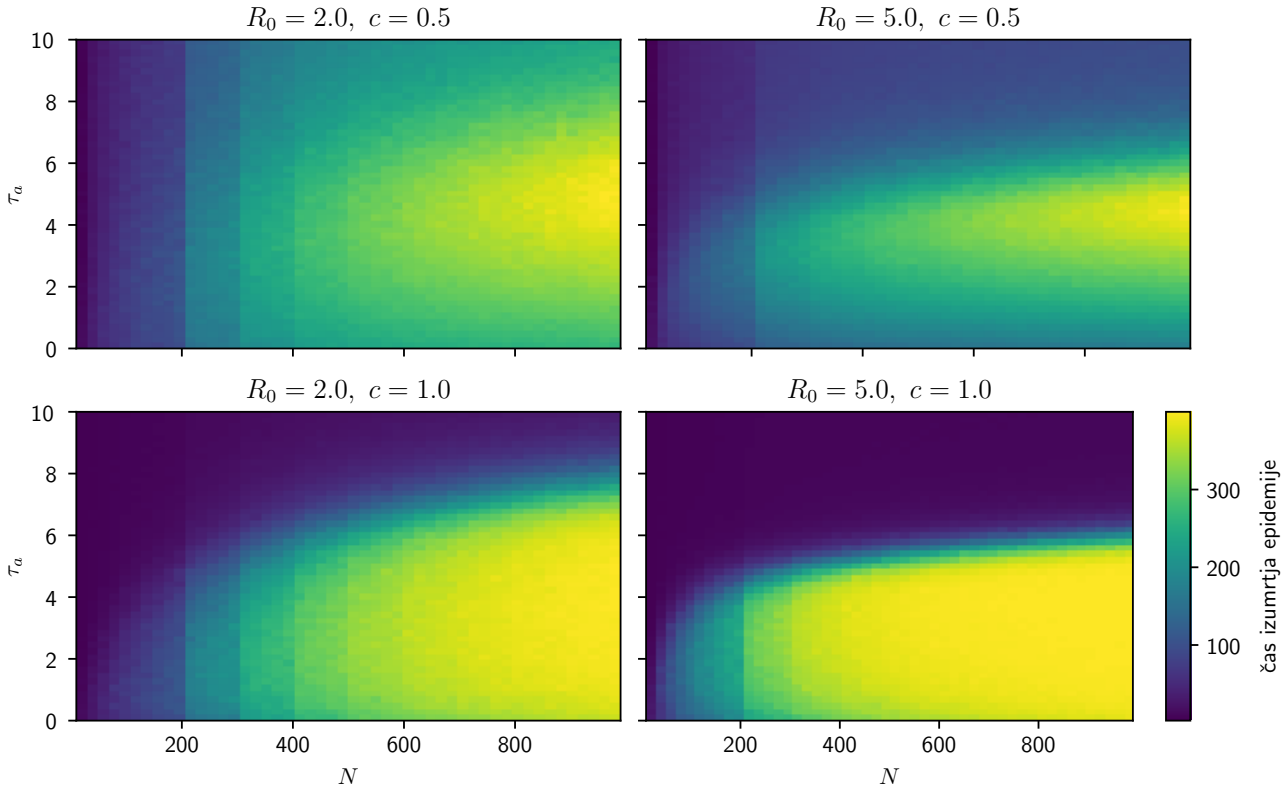
kot v primeru z manjšim τ_a. V primerih, kjer je $c = 1$ se moramo zavedati, da sploh ni nujno, da je epidemija res prišla do konca ampak se je morda iztekel le čas simulacije $T = 400$.