Filtriranje in spektralna analiza

Wienerjev filter in odpravljanje motenj na slikah

Jakob Jerič, 28252025
Fakulteta za matematiko in fiziko, Univerza v Ljubljani
jj06142@student.uni-lj.si

9. december 2025

Naloga

1. Signaloma s 512 točkami na datotekah `val2.dat` in `val3.dat` določi frekvenčni spekter. Preskusi različne okenske funkcije. Kako se spremeni spekter, če analiziramo krajše intervale (64, 128, ..., točk)?

   Signal $u(t)$, ki prihaja v merilno napravo s prenosno funkcijo $r(t)$, se ob dodatku šuma $n(t)$ preoblikuje v
   $$c(t) = u(t) * r(t) + n(t) = s(t) + n(t).$$

   Iz izmerjenega časovnega poteka $c(t)$ bi radi, ob poznavanju odzivne funkcije $r(t)$ in ob nekaterih predpostavkah o šumu $n(t)$, rekonstruirali vpadni signal $u(t)$. N. Wiener je predlagal naslednjo rešitev, ki sledi iz minimizacije napake po metodi najmanjših kvadratov. Pred dekonvolucijo je treba transformiranko $C(f)$ pomnožiti s filtrom
   $$\Phi(f) = \frac{|S(f)|^2}{|S(f)|^2 + |N(f)|^2}.$$

2. S pomočjo Wienerjevega filtra napravi dekonvolucijo signalov na datotekah `signal{0,1,3,4}.dat`. Število točk v posameznem signalu je 512. Na zadnjih treh datotekah je signalu primešan šum. Prenosna funkcija je
   $$r(t) = \frac{1}{2\tau} \exp(-|t|/\tau), \qquad \tau = 16.$$

   V fotografiji imamo pogosto opravka s popačitvami konvolucijske narave: razmazanje zaradi gibanja (motion blur), tresenje objektiva med ekspozicijo, slabo fokusiranje, različne optične aberacije. V primeru, da poznamo prenosno funkcijo (t. i. point spread function), lahko posežemo po dekonvolucijskih metodah, s katerimi lahko do neke mere rekonstruiramo originalno fotografijo, odvisno seveda od zrnatosti fotografije.

3. Poskusi očistiti podobe Lene (datoteke oblike `lena_kX_nY.pgm`) v arhivu `lena_slike.tar.gz`, razmazane s tremi znanimi konvolucijskimi jedri: tresoč objektiv (`kernel1.pgm`), slab fokus (`kernel2.pgm`) ter uklonska mrežica (`kernel3.pgm`). Datotekam je primešana različna količina Gaussovega šuma (RMS = 0, 4, 8, 16).

   Pri filtriranju uporabi Wienerjev filter. Po potrebi je smiselno tudi direktno maskirati okolice valovnih vektorjev, kjer je prenosna funkcija singularna. Upoštevaj tudi, da spektralne metode sliko razumejo v periodičnem smislu, kar ustvari ostre skoke na robu. Ugotovi, ali lahko z okenskimi funkcijami ali razširitvijo slike s konstantnimi vrednostmi zmanjšaš vpliv artefaktov na robu.

   Poskusi tudi očistiti sliko z dodano periodično motnjo (`*_nx.pgm`).

Določanje spektra signala

Vsakemu signalu lahko določimo frekvenčni spekter s pomočjo Fourierjeve transformacije, definirane v krožni frekvenci ω:

$$F(\omega) = \int_{-\infty}^{\infty} f(t)\, e^{-i\omega t}\, dt.$$

V praksi pa nimamo opravka z zveznim signalom na neskončnem intervalu, temveč imamo na voljo le diskretne vrednosti signala na končnem časovnem območju. Zato pri numeričnih analizah uporabimo *diskretno Fourierjevo transformacijo* (DFT)

$$F_k = \sum_{n=0}^{N-1} f_n\, e^{-i\frac{2\pi kn}{N}}, \qquad k = 0, 1, \ldots, N-1.$$

Frekvenčni indeks k lahko pretvorimo v krožno frekvenco z

$$\omega_k = \frac{2\pi k}{N\,\Delta t}.$$

Za izračun DFT uporabimo v Pythonu vgrajeno funkcijo `numpy.fft.fft`.

Pri analizi diskretnih signalov pogosto naletimo na t. i. *uhajanje spektra* (leakage). Do njega pride zato, ker DFT samodejno predpostavi, da je signal na opazovanem intervalu periodičen, kar pa običajno ni res. Razlika med vrednostma signala na robovih zato ustvari umetne diskontinuitete, ki se v frekvenčni domeni pokažejo kot razmazane spektralne črte in povečana energija tam, kjer je v resnici ne bi smelo biti. Da to zmanjšamo, signal pred izračunom DFT pomnožimo z *okensko funkcijo*, ki zgladi prehod proti robovom in tako zmanjša vpliv teh diskontinuitet. Množenje poteka preprosto po točkah, in za diskretni signal $c(n)$ ter okno $w(n)$ dobimo

$$c_w(n) = c(n)\, w(n).$$

Spodaj so prikazane nekatere okenske funkcije, ki jih bomo uporabili pri določitvi frekvenčnega spektra dveh signalov.

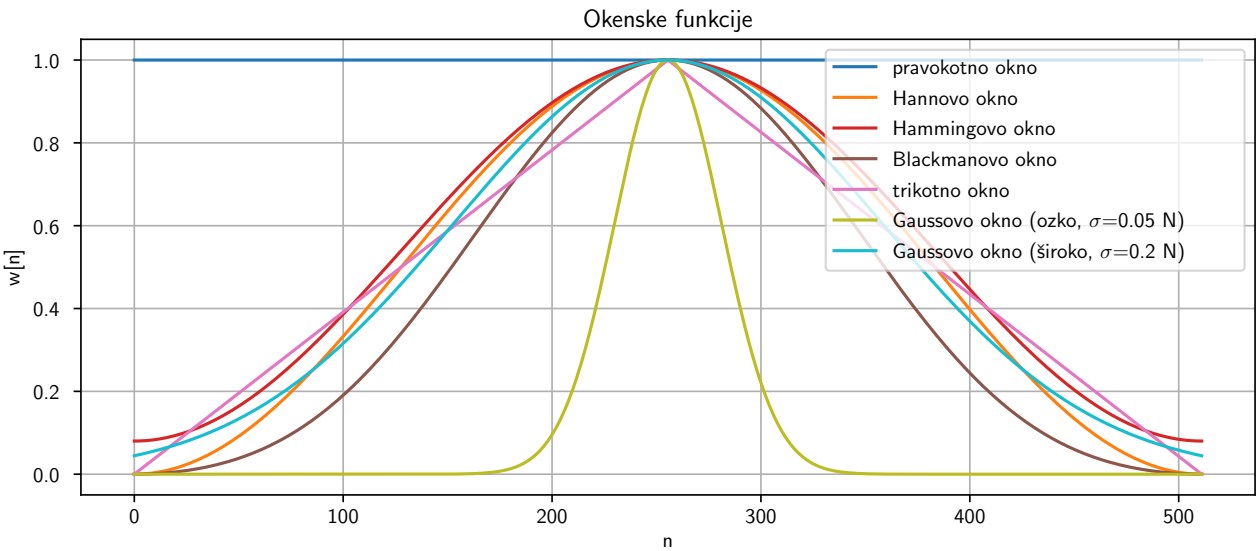

Slika 1

Pri diskretnih signalih lahko pravilno rekonstruiramo le frekvence do *Nyquistove frekvence*

$$f_{\mathrm{Nyq}} = \frac{1}{2\,\Delta t},$$

saj morata biti na vsako periodo zajeta vsaj dva vzorca. Če je vzorčenje prepočasno, se hitrejše komponente preslikajo v napačne, počasnejše frekvence (*aliasing*). Slika 2 prikazuje primer dobro vzorčenega signala (levo) ter aliasinga pri prenizki vzorčni frekvenci (desno): v obeh primerih gre za isti sinus, razlika je le v številu vzorcev. Pri premalem številu vzorcev dejanske točke ne ločijo več hitre komponente, temveč ustrezajo počasnejšemu aliasiranemu signalu (črtkano).

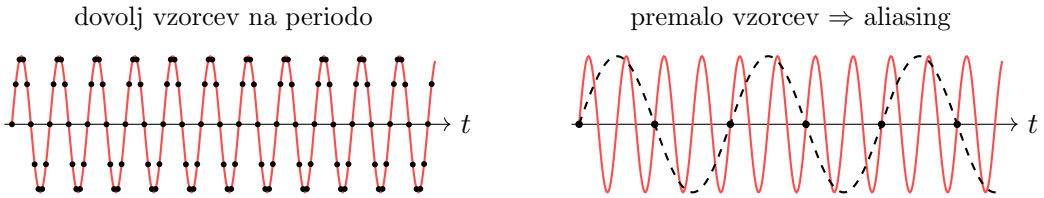

Slika 2: Levo: sinusni signal z dovolj vzorci. Desno: pri prenizki vzorčni frekvenci isti signal povzroči vzorce, ki ustrezajo počasnejšemu aliasiranemu signalu (črtkano).

DFT vrne N frekvenčnih koeficientov, pri čemer indeks k ustreza frekvenci

$$f_k = \frac{k}{N\,\Delta t}.$$

Najvišja smiselna frekvenca je dosežena pri $k = N/2$, zato pri realnih signalih zadostuje analiza prve polovice spektra.

Ker nas pri nadaljnji obdelavi zanima, koliko energije nosi signal pri posameznih frekvencah, uporabljamo moč spektra

$$|F_k|^2,$$

ki jasno pokaže razmerje med signalom in šumom. Spodaj je prikazan frekvenčni spekter obeh signalov, izračunan iz DFT in zglajen z okenskimi funkcijami iz prejšnjega razdelka.

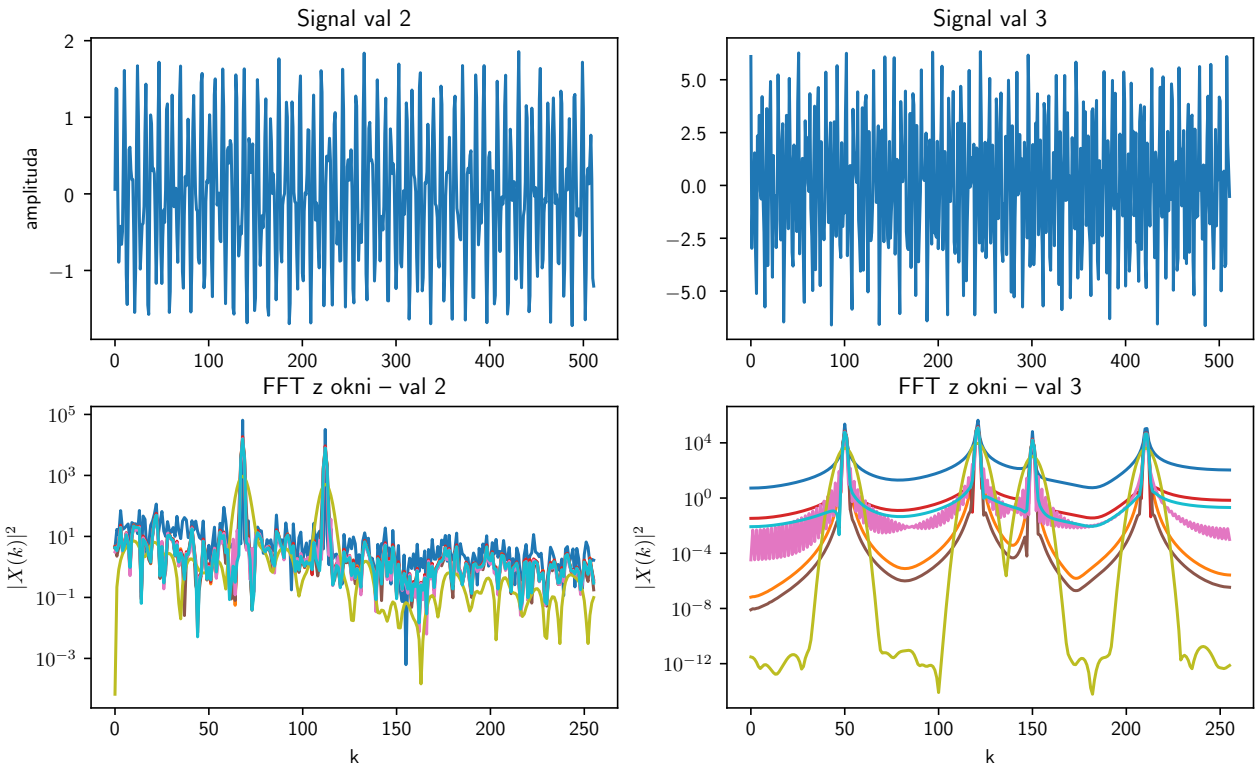

Slika 3

Opazimo, da ožja okenska funkcija resnično pomeni manj puščanja v sosednje frekvence, a moramo biti pri širini okenske funkcije vseeno previdni, saj v primeru, ko sem za okensko funkcijo uporabil zelo ozko Gaussovko nisem mogel dovolj natančno določiti frekvence našega signala, čeprav je bilo puščanje v bolj oddaljenih frekvencah res majhno.

Spodnji grafi pa prikazujejo kako se frekvenčni spekter spremeni, če za analizo vzamemo krajše intervale signala.

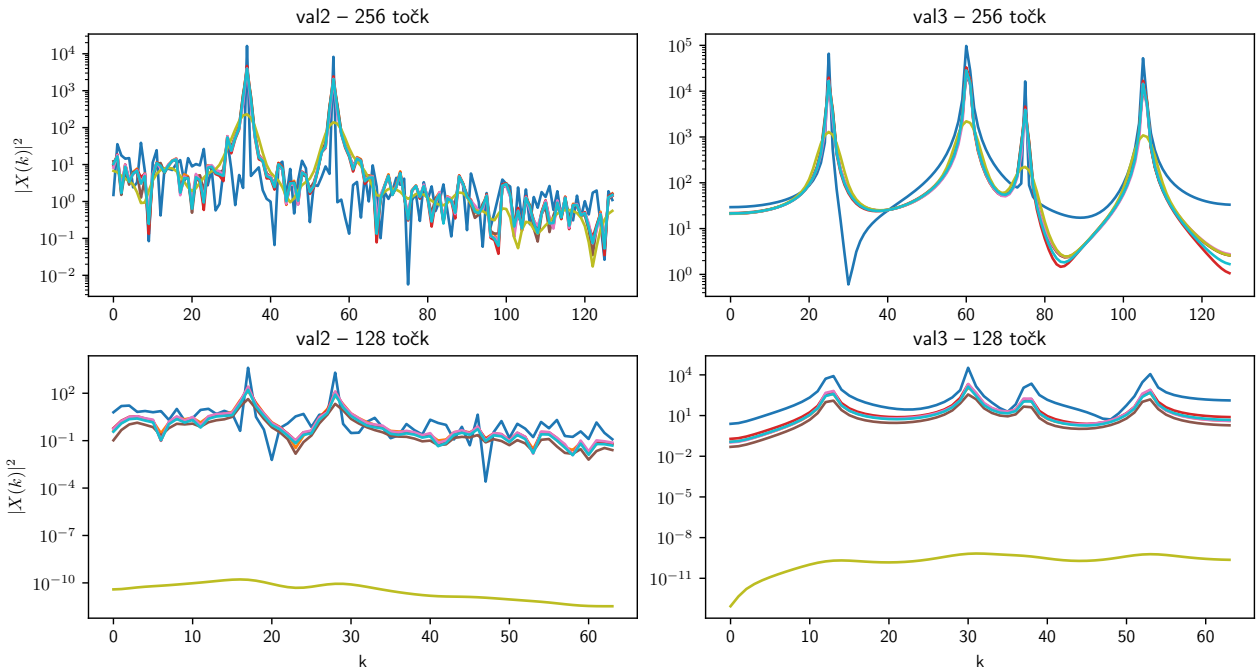

Slika 4

Opazimo, da se zaradi aliasinga zmanjšuje maksimalna vrednost frekvence, ki jo lahko prikažemo – Nyquistova frekvenca. Prav tako pa dobimo tudi frekvence pri nižjih vrednostih, ki jih prej ni bilo.

Wienerjev filter in dekonvolucija signala

Pri obdelavi signalov v praksi pogosto ne merimo neposredno izvornega signala $u(t)$. Meritveni sistemi namreč vedno do neke mere vplivajo na signal: zaradi svojih fizikalnih lastnosti ga zgladijo, razmažejo ali spremenijo njegovo amplitudo. Takšne učinke lahko zelo natančno opišemo s prenosno oziroma impulzno odzivno funkcijo sistema $r(t)$. Izmerjeni signal zato ni več izvirni potek, temveč

$$c(t) = u(t) * r(t) + n(t),$$

kjer je $n(t)$ aditivni šum, ki se pri meritvah neizogibno pojavi. Konvolucija določa osnovno obliko opazovanega signala, šum pa doda naključne deformacije, ki otežijo rekonstrukcijo izvornega poteka.

Na sliki 5 je prikazan signal, konvoluiran z $r(t) = \frac{1}{2\tau}e^{-|t|/\tau}$ in obremenjen z različnimi stopnjami šuma.

Na sliki 6 je prikazan pripadajoči frekvenčni spekter $|C(k)|^2$. Ker predpostavimo, da je aditivni šum beli šum, se v spektru pojavi kot približno konstantna energijska raven čez vse frekvence. Iz grafa lahko zato neposredno ocenimo stopnjo šuma v posameznem primeru.

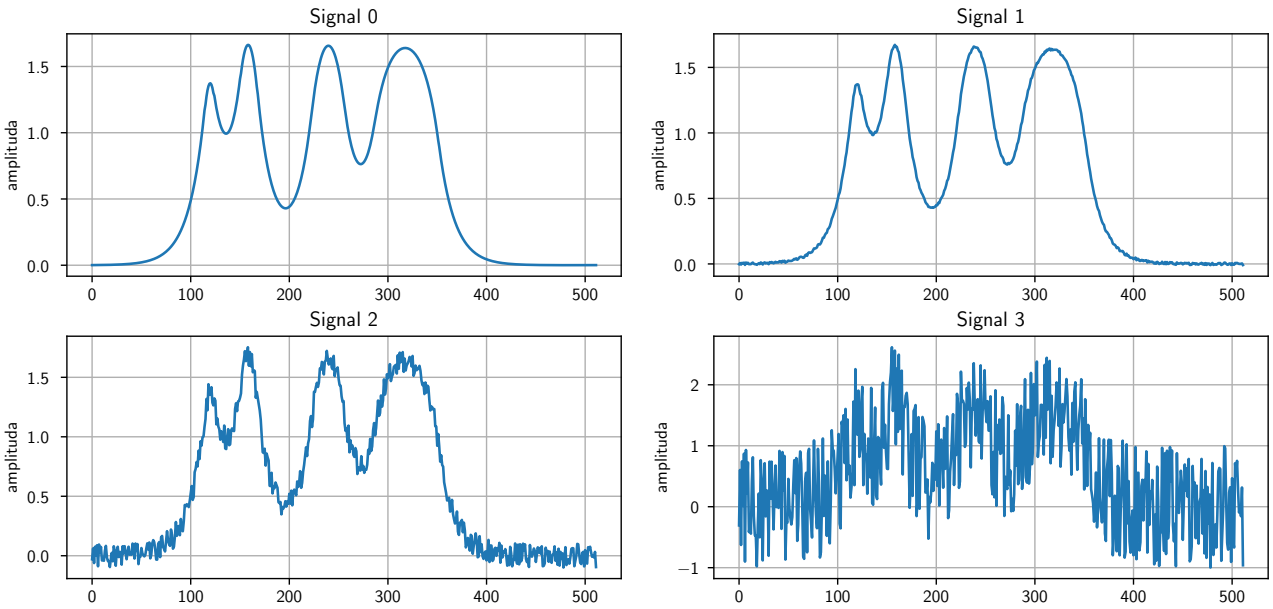

Slika 5

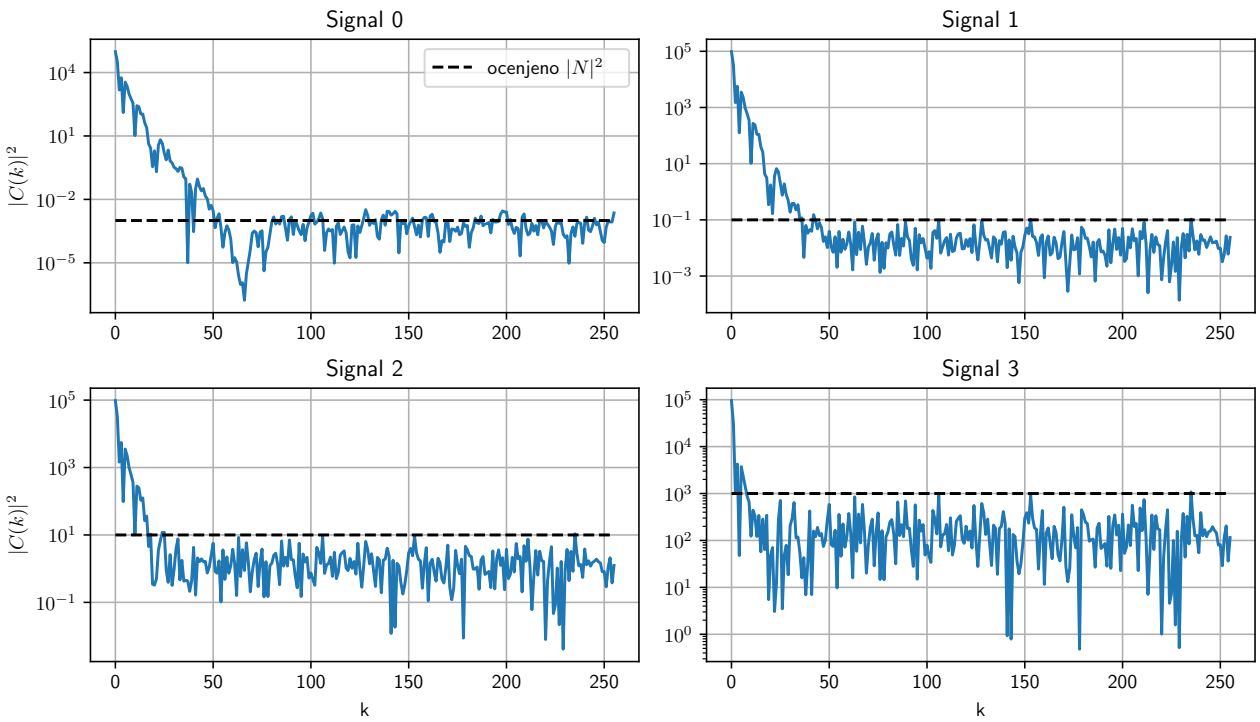

Slika 6

V frekvenčni domeni lahko konvolucijo zapišemo kot

$$C(\omega) = U(\omega)\, R(\omega) + N(\omega),$$

kjer sta $U(\omega)$ in $C(\omega)$ Fourierjevi transformiranki izvornega in izmerjenega signala, $R(\omega)$ pa je prenosna funkcija sistema. V idealnem primeru brez šuma ($N(\omega) = 0$) bi iz tega lahko neposredno rekonstruirali $U(\omega)$ z deljenjem

$$U(\omega) = \frac{C(\omega)}{R(\omega)}.$$

V praksi pa šum ni ničeln, poleg tega pa je $R(\omega)$ v nekaterih frekvenčnih pasovih zelo majhen. Deljenje z majhnimi vrednostmi $R(\omega)$ povzroči, da se šum $N(\omega)$ tam močno ojači, zato moramo pri dekonvoluciji te frekvence ustrezno omejiti ali zamaskirati.

Wienerjev filter ta problem reši tako, da namesto gole delitve s $R(\omega)$ uvaja frekvenčni faktor

$$\Phi(\omega) = \frac{|U(\omega)R(\omega)|^2}{|U(\omega)R(\omega)|^2 + |N(\omega)|^2},$$

ki upošteva razmerje med močjo signala in šuma. V praksi $|U(\omega)|^2$ ne poznamo, zato ga nadomestimo z oceno iz izmerjenega spektra, moč šuma $|N(\omega)|^2$ pa v naši nalogi dobimo iz spektra na sliki 6 (ob predpostavki belega šuma).

Rekonstruiran spekter dobimo kot

$$U_{\text{est}}(\omega) = \Phi(\omega)\,\frac{C(\omega)}{R(\omega)}.$$

Na ta način se rekonstrukcija pri frekvencah, kjer prevladuje signal, približa idealni delitvi $C(\omega)/R(\omega)$, pri frekvencah, kjer prevladuje šum ali je $R(\omega)$ zelo majhen, pa filter ustrezno zmanjša prispevek. Zato Wienerjev pristop omogoča stabilnejšo in fizikalno smiselnejšo dekonvolucijo kot naivno deljenje.

Na spodnjih grafih lahko vidimo razliko v rekonstrukciji signala, če smo uporabili Wienerjev filter ali pa le naivno deljenje s prenosno funkcijo.

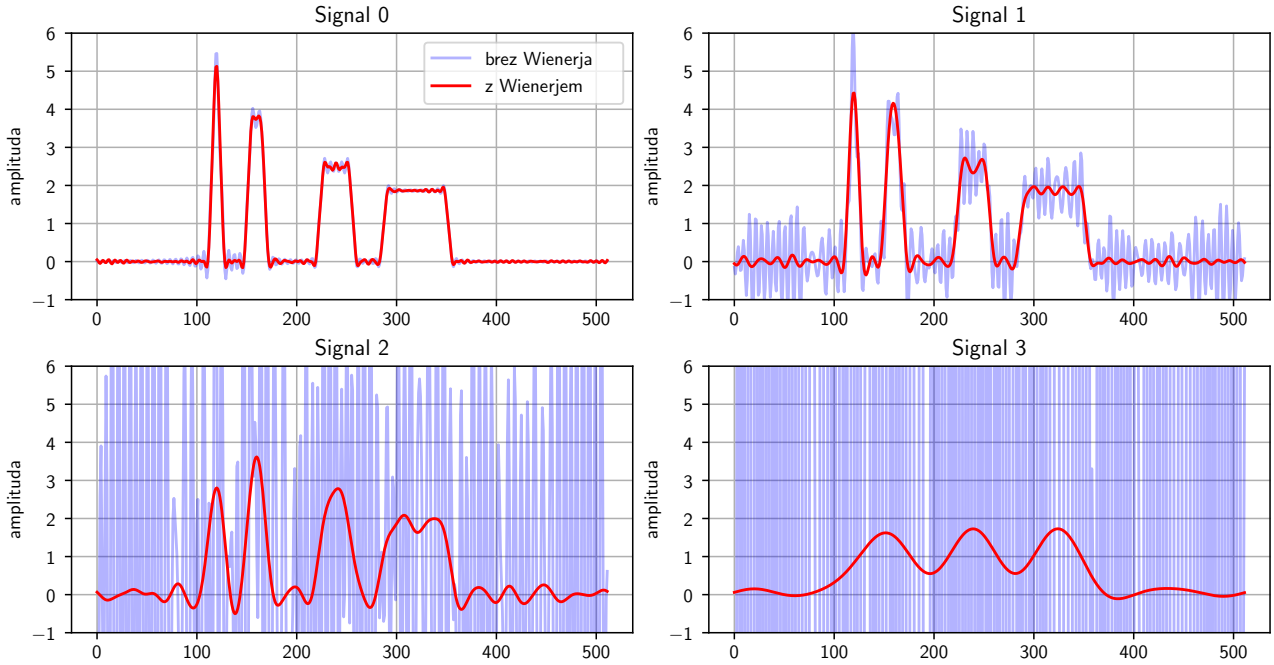

Slika 7

Rekonstrukcija Lenne

Postopek dekonvolucije, ki smo ga opisali v prejšnjem poglavju za enodimenzionalne signale, lahko neposredno posplošimo tudi na dvodimenzionalne podatke. Tipičen primer 2D signala je digitalna slika, pri kateri ima vsaka točka le lokalno vpliv na svoje okolje, zato se zameglitev slike lahko opiše kot dvodimenzionalna konvolucija z ustrezno prenosno funkcijo.

V nadaljevanju bomo poskusili rekonstruirati slike, ki so bile konvoluirane s tremi različnimi 2D prenosnimi funkcijami: tresenjem objektiva, slabim fokusom in uklonsko mrežico. Poleg tega je bila vsaki od teh konvolucij dodana ena izmed štirih različnih stopenj šuma, tako da nastane skupaj dvanajst različnih primerov. Vse kombinacije so prikazane na naslednji strani.

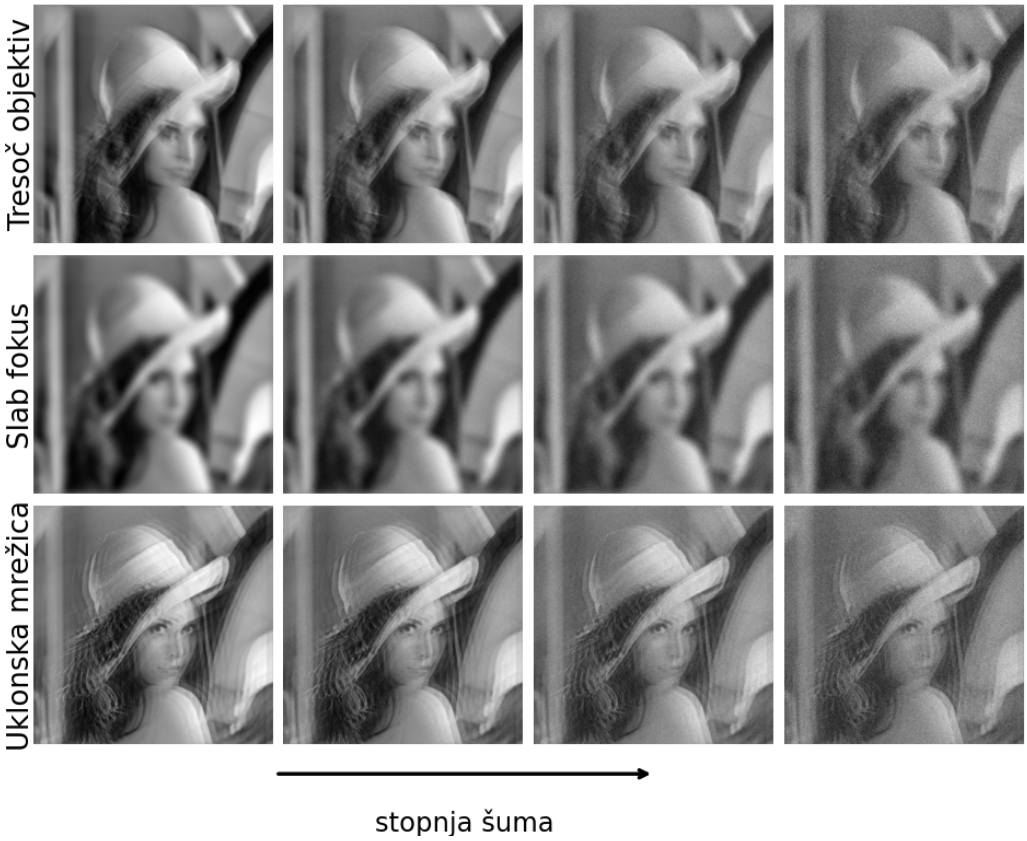

Slika 8

Za vse zgornje slike lahko z 2D Fourierjevo transformacijo določimo frekvenčni spekter, prikazan na spodnjem grafu. Postavitev grafov vseh nadaljnjih ustreza razporeditvi slik zgoraj.

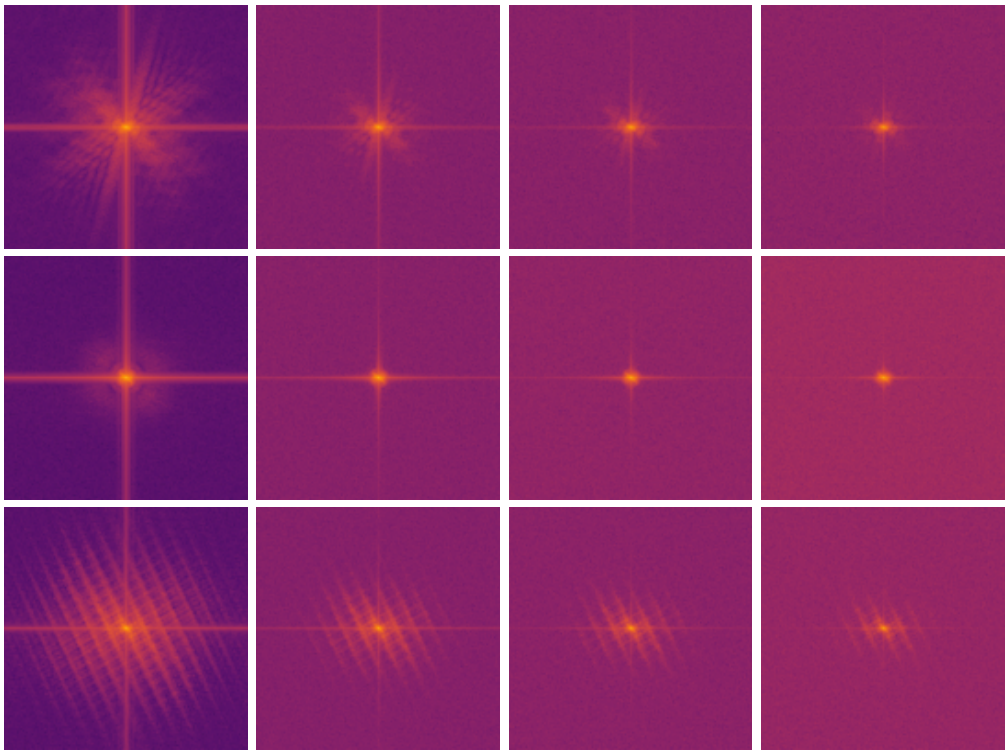

Slika 9

Ker pa iz grafov na prejšnji strani težko ocenimo stopnjo šuma - barvna skala je v logaritemski skali in tudi vsak odtenek težko določimo natančno, spodnji grafi prikazujejo vrednost zgornjih transformirank na diagonali.

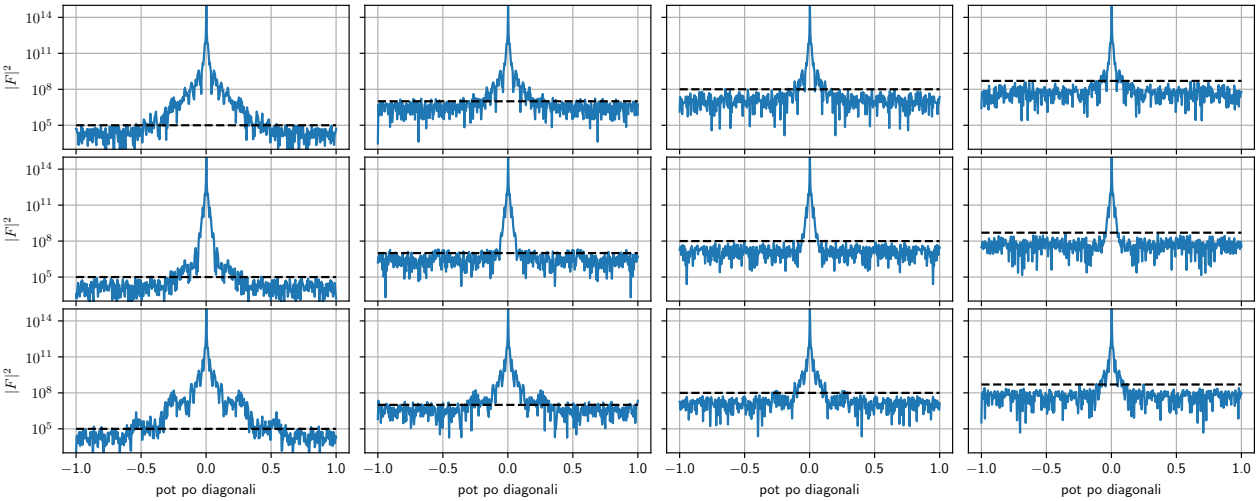

Slika 10

x-os na zgornjih grafih torej prikazuje vrednost pozicije na diagonali v frekvenčni domeni, y-os pa vrednost spektra na tej poziciji. Iz zgornjih grafov tako veliko lažje določimo ocene moči belega šuma za vsako sliko posebej.

Ker poznamo prenosno funkcijo za vsako sliko ter smo iz zgornjih grafov lahko dobili oceno moči belega šuma, lahko na popolnoma enak način sedaj preprosto naredimo Wienerjev filter v dveh dimenzijah in rekonstruiramo slike.

Slika 11

Na zgornji strani so prikazane rekonstrukcije slik, ki smo jih dobili na opisani način. Opazimo, da imajo slike dokaj slab kontrast in da se v njih pojavljajo izrazite robne strukture, ki kvarijo podobo. Te artefakte povzroči dejstvo, da se slika na robovih nenadoma konča; v Fourierjevem prostoru se to pokaže kot skok oziroma diskontinuiteta, ki močno vpliva na postopek dekonvolucije.

Težavo lahko omilimo na dva načina. Prvi pristop je, da sliko umetno povečamo izven območja, ki nas dejansko zanima. To storimo tako, da ob vsakem robu dodamo pas pikslov enake vrednosti, kot jo ima robni piksel izvirne slike. Tako preprečimo nenaden prehod in s tem zmanjšamo robne artefakte v frekvenčni domeni. Rezultat takšnega postopka je prikazan na spodnji sliki.

Slika 12

Drugi pristop za zmanjšanje robnih artefaktov pa je uporaba okenskih funkcij, podobno kot smo to storili že pri prvi nalogi. Namesto da sliko razširimo, jo pred transformacijo pomnožimo z izbrano 2D–okensko funkcijo, ki gladko zmanjša vrednosti proti robu in tako prepreči nenadne skoke pri periodični razširitvi slike v Fourierjevi domeni. Na sliki 13 je prikazana rekonstruirana slika, dobljena z uporabo Hammingovega okna, na sliki 14 pa enak postopek, izveden z nekoliko ožjim Blackmanovim oknom. Razlika med obema primeroma pokaže, kako izbira okna vpliva na kompromis med zmanjšanjem robnih artefaktov in velikostjo sredinskega dela, ki ima dober kontrast.

Slika 13

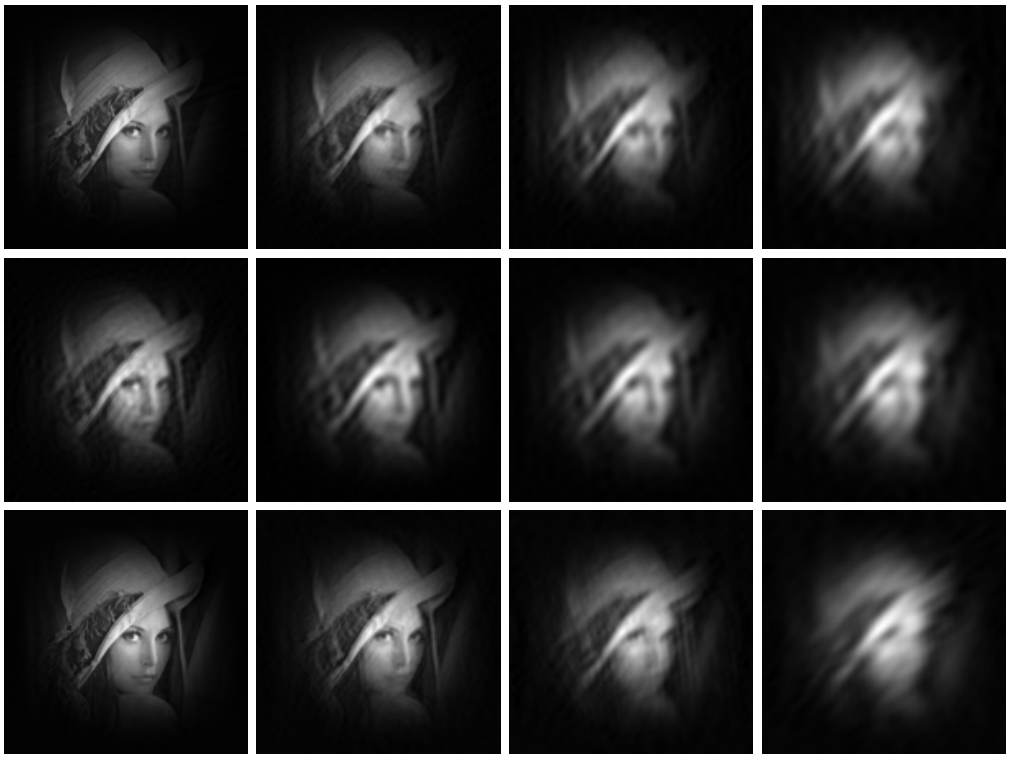

Slika 14