Metoda maksimalne entropije in linearna napoved

Analiza frekvenčnega spektra in napoved obnašanja sistemov

Jakob Jerič, 28252025
Fakulteta za matematiko in fiziko, Univerza v Ljubljani
jj06142@student.uni-lj.si

6. januar 2026

Naloga

1. Določi frekvenčni spekter signalov iz datotek `val2.dat`, `val3.dat` in `co2.dat` z metodo maksimalne entropije. V slednji datoteki s koncentracijo CO_2 v zraku upoštevaj splošen (linearen) letni trend. Preizkusi delovanje metode v odvisnosti od števila polov in od gostote prikaza. Pri CO_2 si oglej še njihovo lego. Primerjaj natančnost metode z rezultati, ki jih da FFT ob uporabi filtrov. Sestavi tudi testni signal iz vsote sinusnih členov z bližnjimi frekvencami ter razišči ločljivost metode.

2. Koeficiente metode maksimalne entropije na signalih iz prve naloge uporabi za linearno napoved: koeficiente določi iz prve polovice zapisa signala, drugo polovico pa uporabi za primerjavo z napovedjo. Priporočljivo je majhno število polov. Ugotovi, kako vpliva na napoved šum! Podobno preuči datoteko `borza.dat` in podatke za lunine efemeride v `luna.dat`, oziroma sončni cikel `Wolf_number.dat`. Preveri, ali so vsi koreni preslikavne funkcije znotraj enotnega kroga, in jih po potrebi preslikaj vanj!

Frekvenčni spekter z metodo maksimalne entropije

Signal obravnavamo kot časovno zaporedje meritev in predpostavimo, da se njegove osnovne lastnosti v času bistveno ne spreminjajo. Opisali smo ga z avtoregresijskim modelom reda p, pri katerem vsak vzorec izrazimo kot linearno kombinacijo prejšnjih p vzorcev. Iz danih podatkov najprej izračunamo avtokorelacijo

$$R(k) = \frac{1}{N-k} \sum_{n=k+1}^{N} s_n \, s_{n-k},$$

za $k = 0, \ldots, p$. Na podlagi teh vrednosti sestavimo simetrično matriko

$$\begin{pmatrix} R(0) & R(1) & \cdots & R(p-1) \\ R(1) & R(0) & \cdots & R(p-2) \\ \vdots & \vdots & \ddots & \vdots \\ R(p-1) & R(p-2) & \cdots & R(0) \end{pmatrix},$$

in rešimo sistem linearnih enačb

$$\begin{pmatrix} R(0) & R(1) & \cdots & R(p-1) \\ R(1) & R(0) & \cdots & R(p-2) \\ \vdots & \vdots & \ddots & \vdots \\ R(p-1) & R(p-2) & \cdots & R(0) \end{pmatrix} \begin{pmatrix} a_1 \\ a_2 \\ \vdots \\ a_p \end{pmatrix} = - \begin{pmatrix} R(1) \\ R(2) \\ \vdots \\ R(p) \end{pmatrix}.$$

S tem dobimo koeficiente a_k, ki najbolje opišejo odvisnost signala od njegovih preteklih vrednosti.

Dobljene koeficiente nato uporabimo za izračun frekvenčnega spektra. Za različne frekvence ovrednotimo izraz

$$1 + \sum_{k=1}^{p} a_k \, \mathrm{e}^{-i\omega k}$$

in iz njega izračunamo spektralno gostoto

$$P(\omega) = \frac{1}{\left|1 + \sum_{k=1}^{p} a_k \, \mathrm{e}^{-i\omega k}\right|^2}.$$

Vrhovi v spektru se pojavijo pri tistih frekvencah, kjer je imenovalec majhen, kar je povezano s poli v kompleksni ravnini, ki ležijo blizu enotske krožnice. Ker so koeficienti a_k realni, se poli vedno pojavijo v kompleksno konjugiranih parih.

Spodaj je prikazana relativna moč frekvenčnega spektra, ki sem jo dobil po zgoraj opisani metodi za različne vrednosti števila polov p ter njihove vrednosti prikazane v kompleksni ravnini.

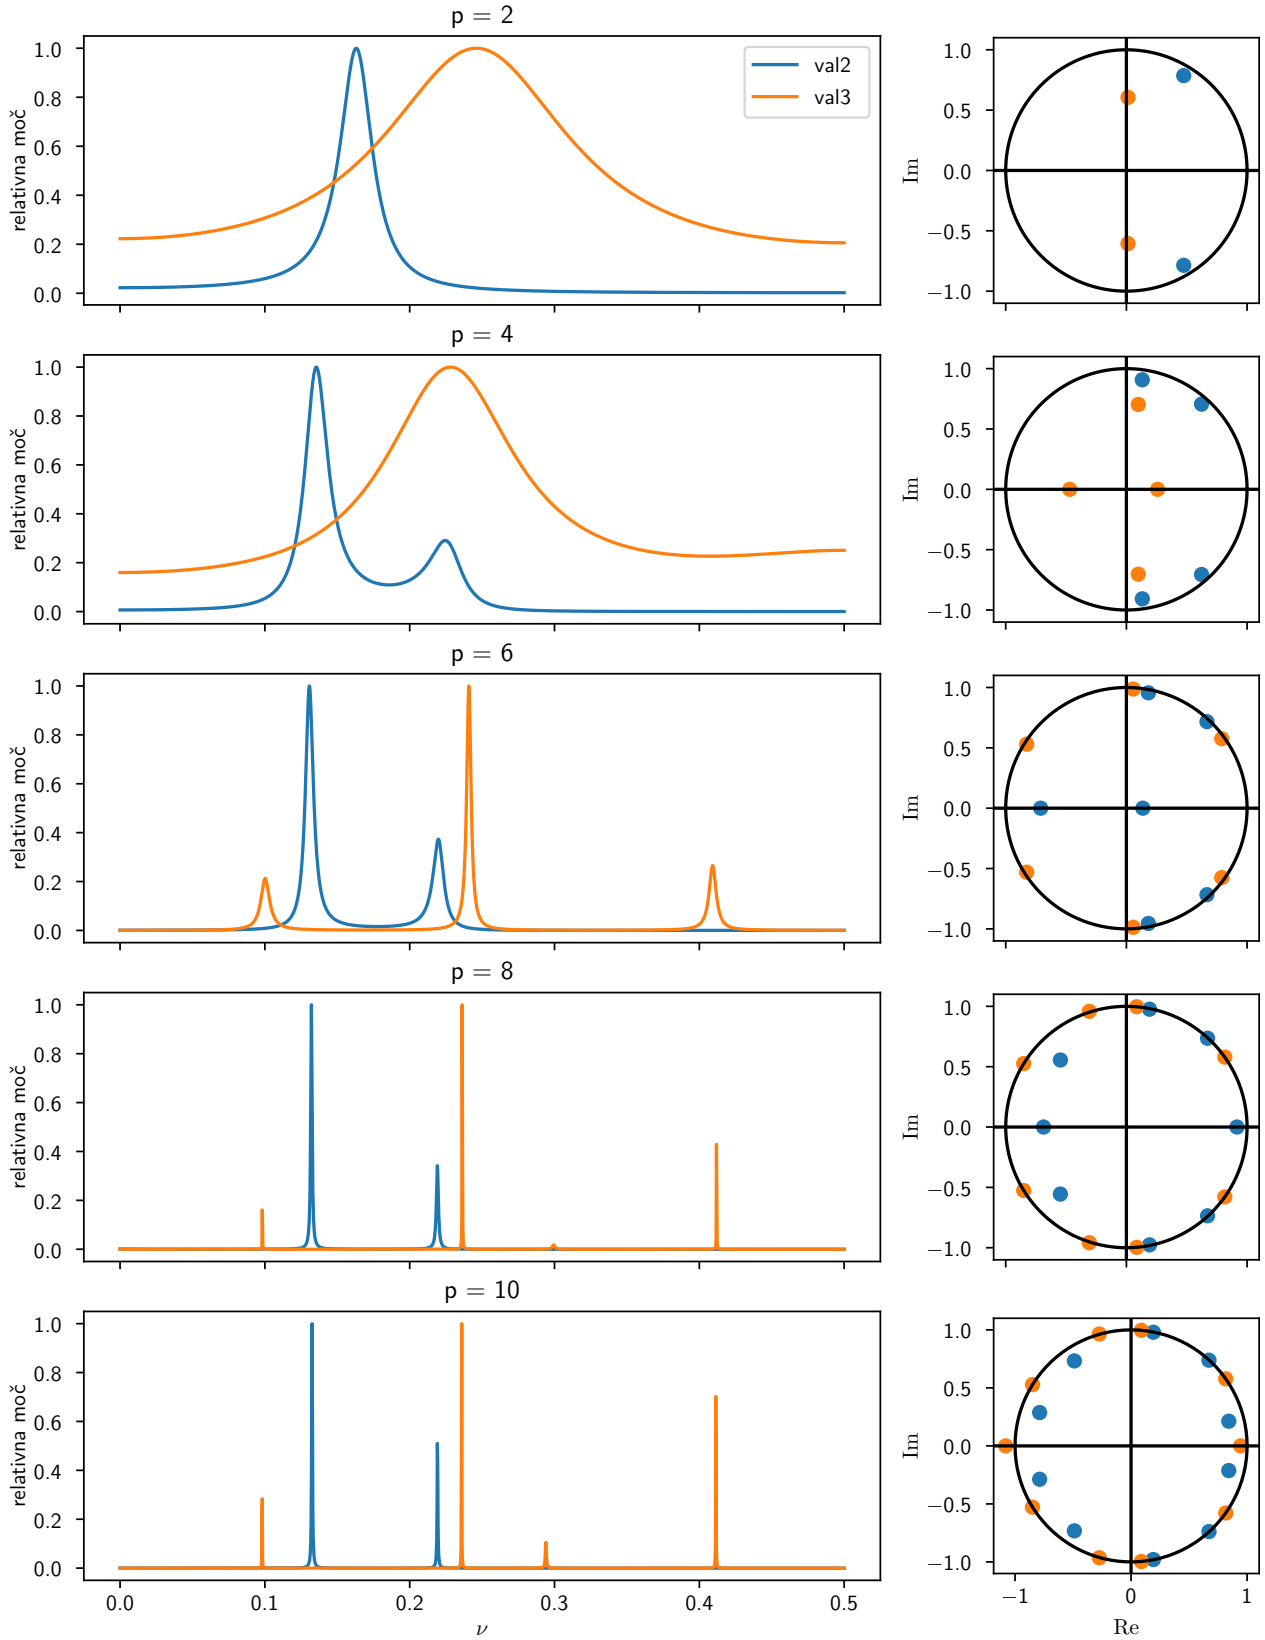

Slika 1

Opazimo, da število vrhov, ki jih dobimo v spektru resnično ustreza $\frac{p}{2}$. Prav tako lahko opazimo, da se z večanjem števila p vrhovi v spektru izostrijo in postanejo bolj izraziti. V kompleksni ravnini pa lahko vidimo, da poli resnično nastopajo v kompleksno konjugiranih parih. Frekvenca $\nu = 0,5$ v zgornjih in v vseh nadaljnih grafih ustreza Nyquistovi frekvenci - torej je največja frekvenca, ki jo lahko zabeležimo pri dani frekvenci vzorčenja in ustreza zapisu $+ - + - +$....

Seveda pa lahko naši podatki sledijo tudi nekemu dolgoročnemu trendu. Primer takšnih podatkov je datoteka `co2.dat`, ki vsebuje podatke o koncentraciji CO_2 v zraku skozi čas. Na spodnji sliki, je na levi strani prikazana koncentracija CO_2 skozi čas, kjer lahko opazimo, da podatki sledijo nekemu splošnemu naraščajočemu linearnemu trendu. Na desni strani pa so prikazani enaki podatki, iz katerih smo najprej odšteli linearni trend. Pod predstavljenima grafoma lahko vidimo tudi frekvenčni spekter, ki sem ga dobil na enak način kot pri datotekah `val2.dat` in `val3.dat` - (*Maximum Entropy Method*).

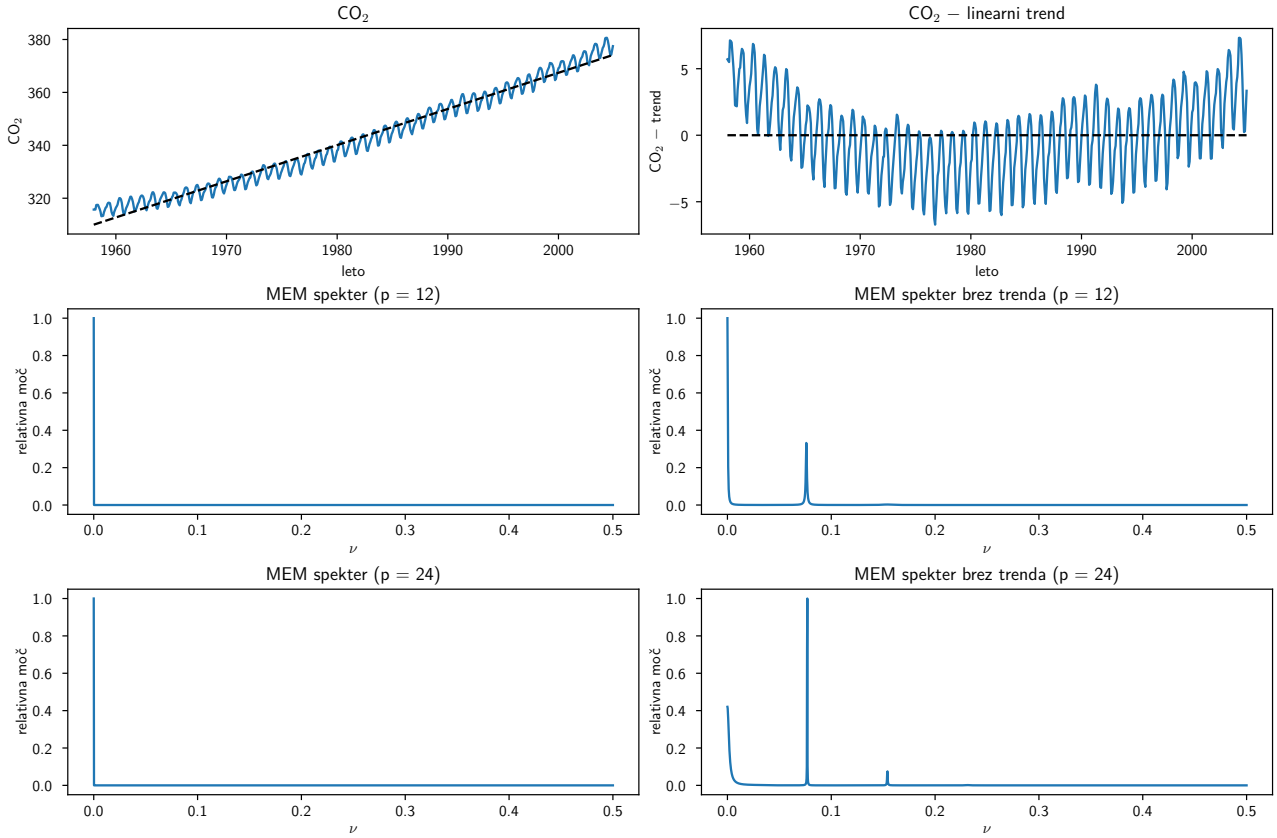

Slika 2

Vidimo, da v primeru, ko linearnega trenda nismo ročno odstranili, v frekvenčnem spektru opazimo le en vrh pri zelo nizki frekvenci, ki ustreza splošnemu naraščajočemu trendu. Ko pa linearni trend odstranimo, se v spektru pojavijo tudi drugi vrhovi, ki ustrezajo letnim in sezonskim ciklom v podatkih.

Poleg MEM metode lahko za izluščevanje frekvenčnega spektra uporabimo tudi dobro poznano Fourierovo transformacijo. Na grafu na naslednji strani je prikazana primerjava med metodoma za datoteki `val3.dat` in `co2.dat` (Slika 3) ter tudi za datoteko `co2.dat` v surovi obliki in z odstranjenim linearnim trendom (Slika 4).

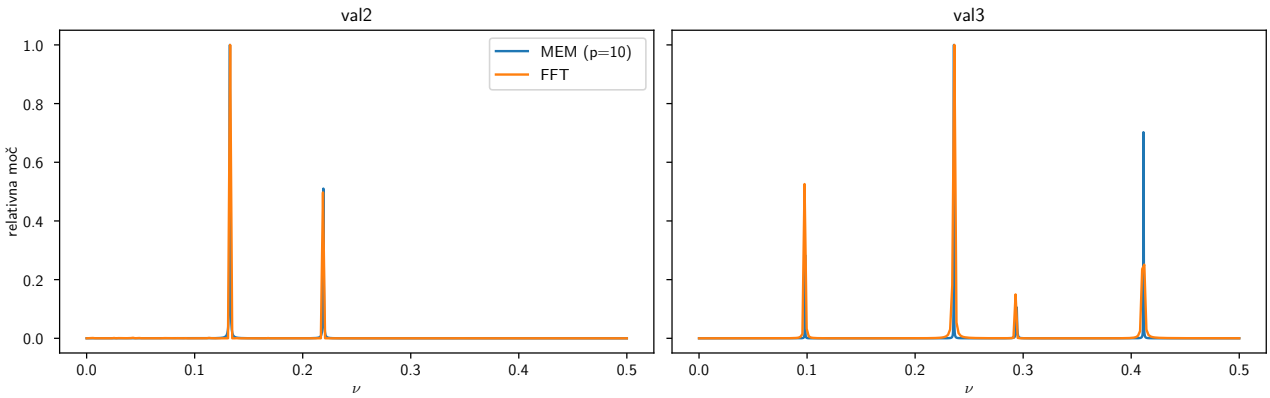

Slika 3

Opazimo, da se v vseh primerih frekvenčni spektri dobljeni z obema metodama precej dobro ujemajo. Vrednosti najdenih frekvenc so popolnoma enake, razlikujejo se le v njihovi relativni moči.

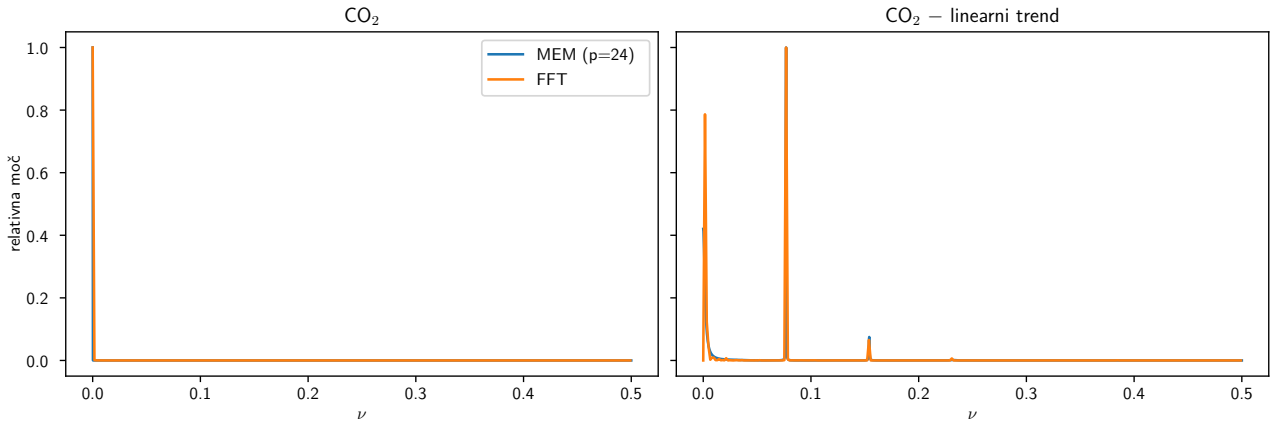

Slika 4

Zakaj bi torej sploh uporabljali metodo maksimalne entropije, če pa lahko uporabimo kar FFT? Ločljivost v frekvenčnem spektru metode FFT je namreč omejena z dolžino signala in velja

$$\Delta\nu_{FFT} = \frac{1}{N\Delta t}.$$

Če imamo torej na voljo le N vzorcev signala, potem z metodo FFT ne moremo ločiti dveh frekvenc, ki se razlikujeta za manj kot $\frac{1}{N\Delta t}$.

Graf na naslednji strani prikazuje, kako obe metodi ločita dve frekvenci, ki se med seboj razlikujeta za Δ v signalu dolžine 1024 vzorcev (Slika 5) in 512 vzorcev (Slika 6).

Ker za določitev 2 frekvenc pri metodi MEM potrebujemo vsaj 4 pole, je v vseh primerih najmanjša vrednost p enaka 4.

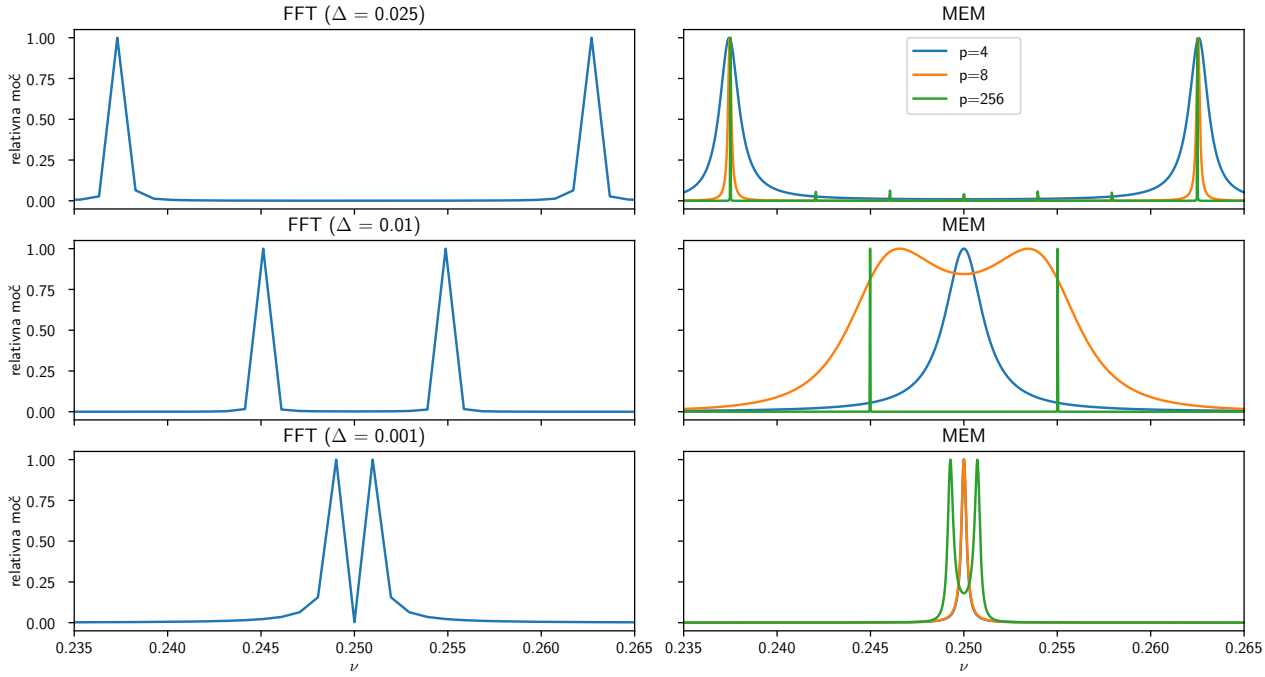

Slika 5: Signal dolžine 1024.

Iz zgornjega grafa vidimo, da smo z metodo FFT lahko ločili vse tri primere, saj je $\Delta = \frac{1}{1000} > \frac{1}{1024}$. Pri metodi MEM pa smo $\Delta = \frac{1}{1000}$ lahko ločili le z največjim številom polov $p = 256$.

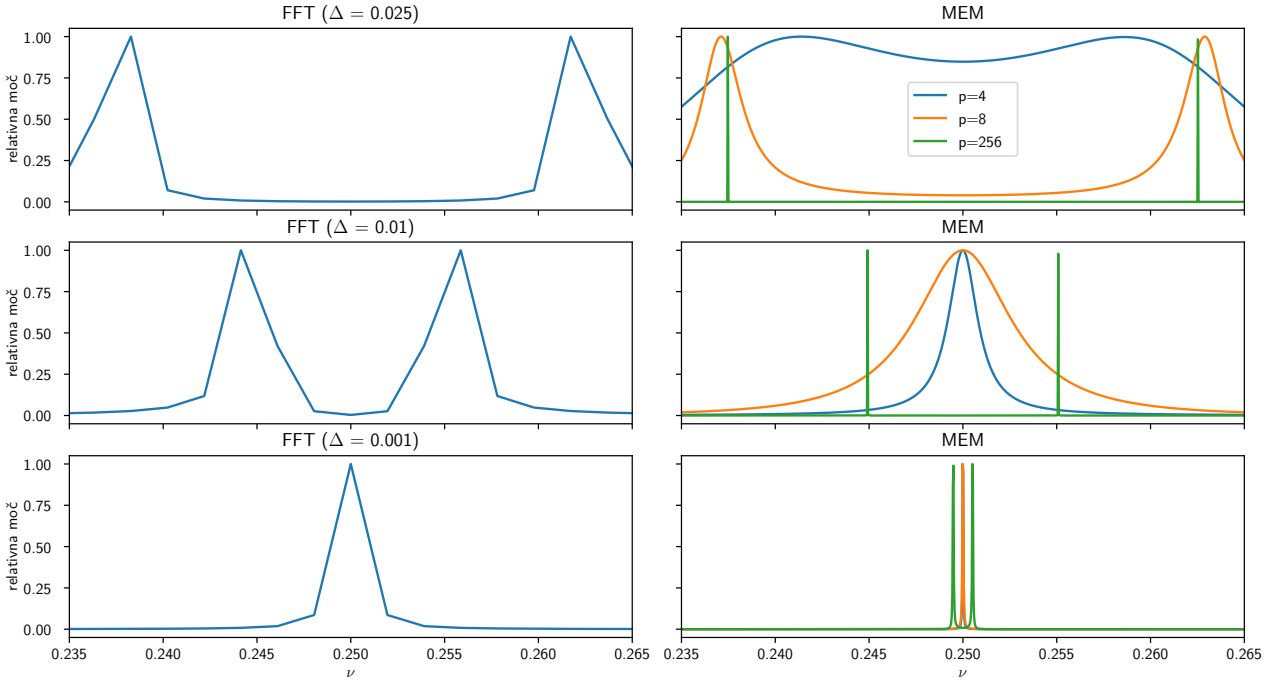

Slika 6: Signal dolžine 512.

Ko sem zmanjšal dolžino signala na 512, z metodo FFT nisem več mogel ločiti $\Delta = \frac{1}{1000}$, ker je sedaj $\Delta = \frac{1}{1000} < \frac{1}{512}$. Z metodo MEM pa sem lahko še vedno ločil vse tri primere, če sem le dovolj povečal število polov p.

Da bi bilje analiziral, koliko polov p potrebujemo, da z metodo MEM ločimo dve frekvenci, sem naredil spodnji graf:

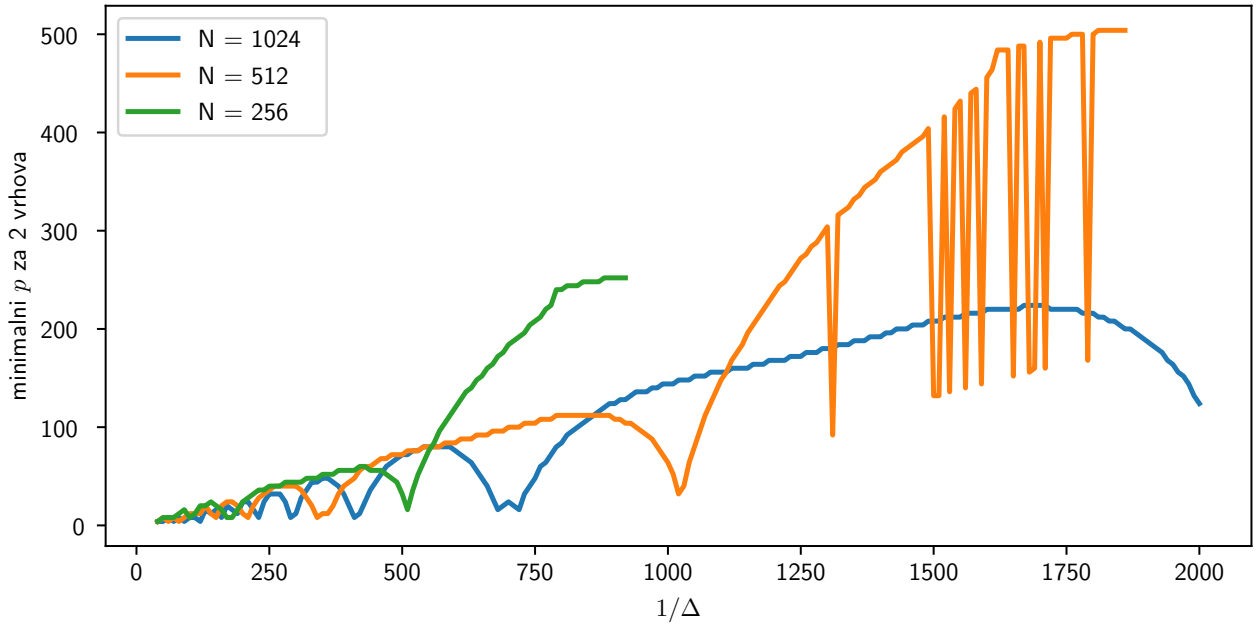

Slika 7

Za signale treh različnih dolžin (256, 512 in 1024 vzorcev) sem pogledal, najmanj koliko polov p potrebujemo, da da v našem frekvenčnem spektri zaznamo 2 vrhova - to še ne pomeni, da smo frekvenci določili natančno (npr. na Sliki 6 pri $\Delta = \frac{1}{400}$ in $p = 4$ vidimo 2 vrhova, ki pa nista na pravih frekvencah) - a vseeno dobimo dobro oceno, da lahko določimo ločljivost metode MEM. Opazimo da število polov ki jih potrebujemo, da z metodo MEM ločimo dve frekvenci kot 2 vrhova narašča linearno z $\frac{1}{\Delta}$ z naklonom približno $\frac{1}{10}$ za vse tri dolžine signalov. Prav tako opazimo, da lahko z metodo MEM in omenjemi številom polov p ločimo frekvenci, ki imata še enkrat manjšo Δ kot je ločljivost metode FFT za signal enake dolžine - kot mejo sem doloočil zadnji minimum, ki ga razberemo iz grafa zgoraj.

Linearna napoved

Koeficiente a_k, določene v prvem delu naloge z metodo maksimalne entropije, lahko uporabimo tudi za linearno napoved nadaljnjega obnašanja signala. Ker ima obravnavani signal neničelno povprečje, v nadaljevanju najprej odštejemo povprečje prve polovice zapisa, $x_n = s_n - \mu$. S tem signal opišemo z avtoregresijskim (AR) modelom reda p, pri katerem trenutno vrednost izražamo kot linearno kombinacijo lastnih preteklih vrednosti.

Za centriran signal tako predpostavimo zvezo

$$\hat{x}_n = -\sum_{k=1}^{p} a_k \, x_{n-k},$$

ki jo uporabimo kot rekurzijo za napoved. Koeficiente a_k določimo iz prve polovice zapisa, nato pa z isto rekurzijo napovedujemo drugo polovico signala; končno napoved dobimo z $\hat{s}_n = \hat{x}_n + \mu$ in jo primerjamo z dejanskimi podatki. Če so vsi poli pripadajoče preslikavne funkcije znotraj enotske krožnice, vpliv začetnih vrednosti s časom pada, zato se napoved pri daljšem napovedovanju postopoma umiri in ostane omejena.

Spodaj so prikazani rezultati za napovedi podatkov iz datoteke *luna.dat* po prej opisanem postopku za različne vrednosti števila polov p.

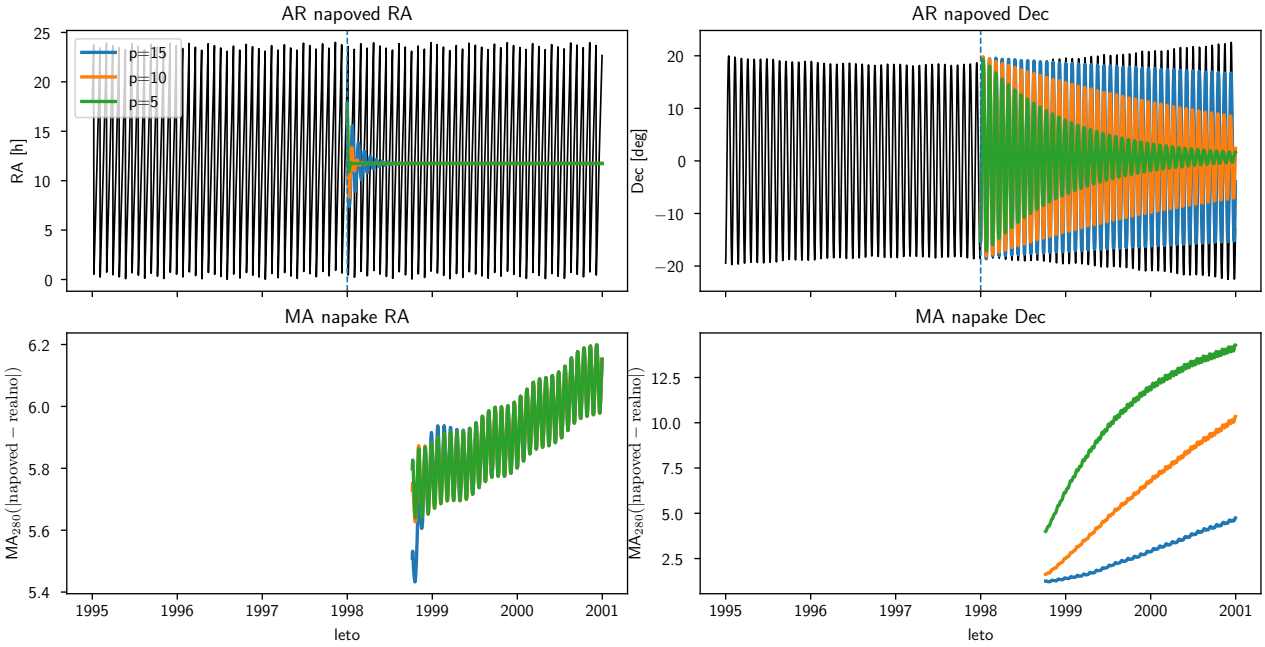

Slika 8

Pod napovedmi za drugo polovico podatkov so prikazane tudi povprečne absolutne napake napovedi (*Moving Average* z dolžino okna 280 - 10 ciklov). Opazimo lahko, da napovedi z manjšim številom polov hitreje konvergirajo k povprečju in imajo tako večjo napako.

Enako napoved lahko naredimo tudi za podatke o številu sončnih peg v datoteki `Wolf_number.dat`. To je s povprečnimi napakami za različne vrednosti p prikazano na spodnjem grafu.

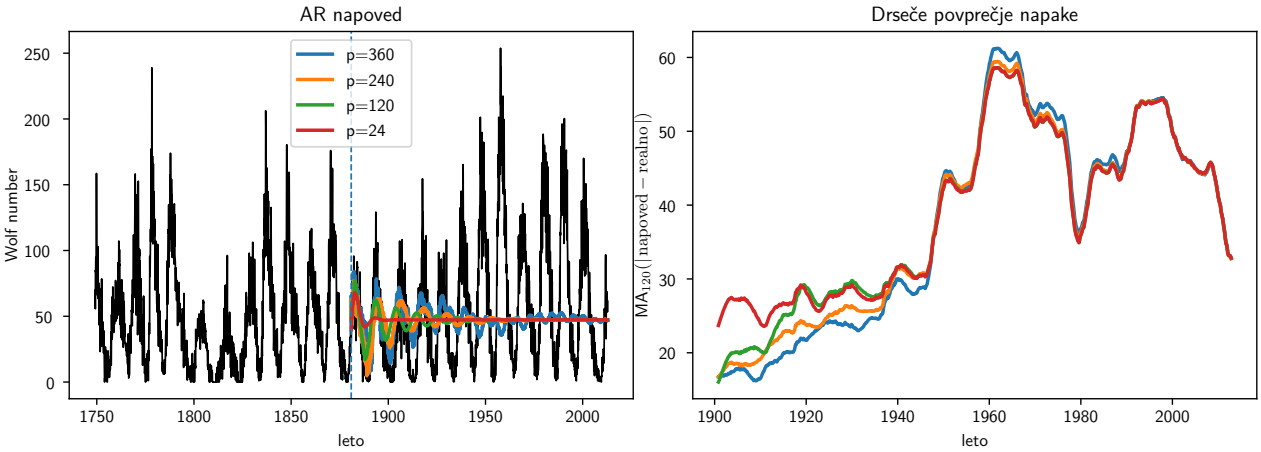

Slika 9

Ponovno opazimo enake značilnosti - napovedi z manjšim parametrom p hitreje konvergirajo k povprečju in imajo večjo napako.

Lahko pogledamo tudi kako na stabilnost naše napovedi in na celotno napako vpliva tudi dodani šum. Datoteki `val2.dat` sem dodal različne stopnje šuma ($\frac{\sigma_{\text{šum}}}{\sigma_{\text{signal}}}$) in za napovedi druge polovice signala z različnimi vrednostmi p meril kumulativno RMS napako napovedi. Modele, ki so imeli vsaj en pol po absolutni vrednosti večji od 1, sem označil za nestabilne in jih tako nisem prikazal na spodnjem grafu.

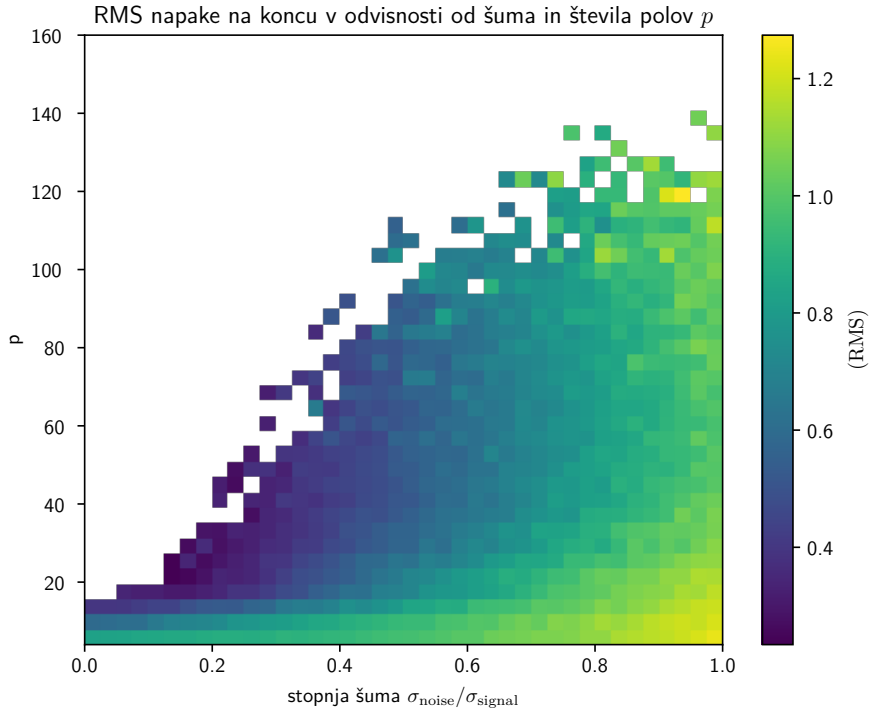

Slika 10

Kot bi pričakovali, nam večje število polov v splošnem da boljši rezultat in tako manjšo skupno napako, dokler ne pridemo do točke, kjer model postane nestabilen. Pričakovano tudi z večjim šumom napaka narašča, kar pa se sprva zdi malce nepričakovano je dejstvo, da se območje stabilnosti z dodajanjem šuma povečuje. Razlog je verjetno v tem, da ob večjem šumu nimamo tako ostro definiranih frekvenc in tako nobeden od polov nima izrazito velike vrednosti, kar pomeni, da so s povečevanjem p vsi poli dalj časa znotraj enotskega kroga v kompleksni ravnini.

Zanimiv primer napovedi je tudi napoved borznih cen. Z enakim pristopom kot pri prejšnjih primerih dobimo rezultat prikazan spodaj:

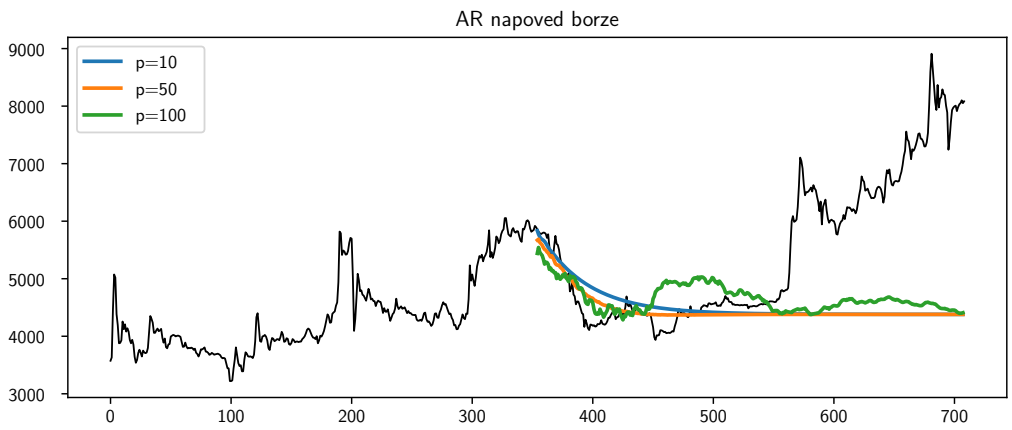

Slika 11

Z grafa na prejšnji strani opazimo, da res dobro napovemo prvi padec, a to je v večinoma samo zaradi približevanja naše napovedi k povprečju. Če bi na primer poskusili napoved iz $\frac{N}{2} = M$ preteklih točk naredili za prihodnjih $H = \frac{M}{5}$ točk in tako naredili nekakšen *rolling* napovedni model, bi dobili spodnji rezultat:

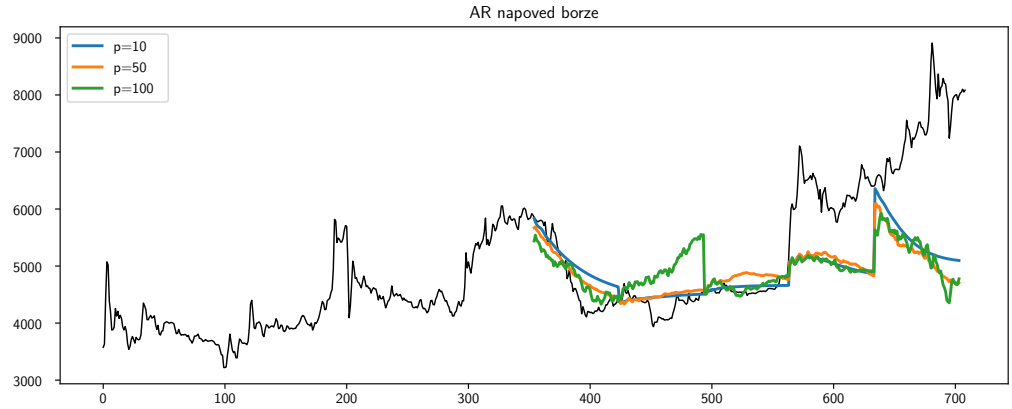

Slika 12

Opazimo da za vse naše p ponovno dobimo le približevanje k povprečjiu praktično neodvisno od realnega obnašanja borznih cen. Tudi če korak napovedi nastavimo na eno samo točko dobimo tako preveč "pesimistično"napoved, saj vedno predvidevamo vrnitev k povprečju - ta primer je prikazan spodaj:

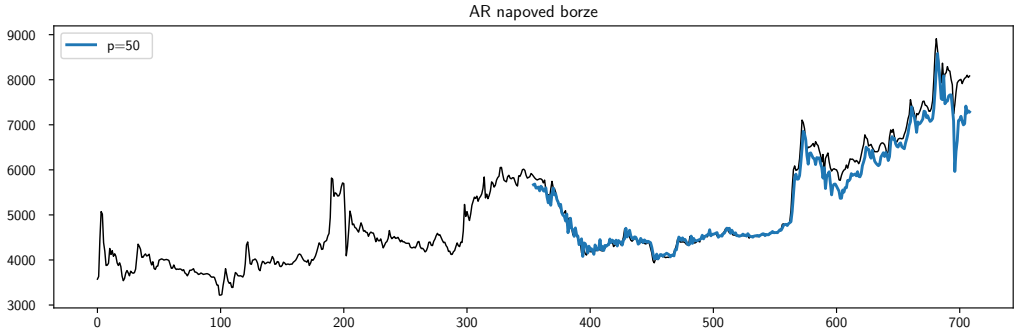

Slika 13

Težave lahko poskusimo rešiti tako, da poleg celotnega povprečja odštejemo še lokalni trend, določen iz predhodnih vrednosti oziroma z uporabo *moving average* filtra. Rezultat je prikazan spodaj:

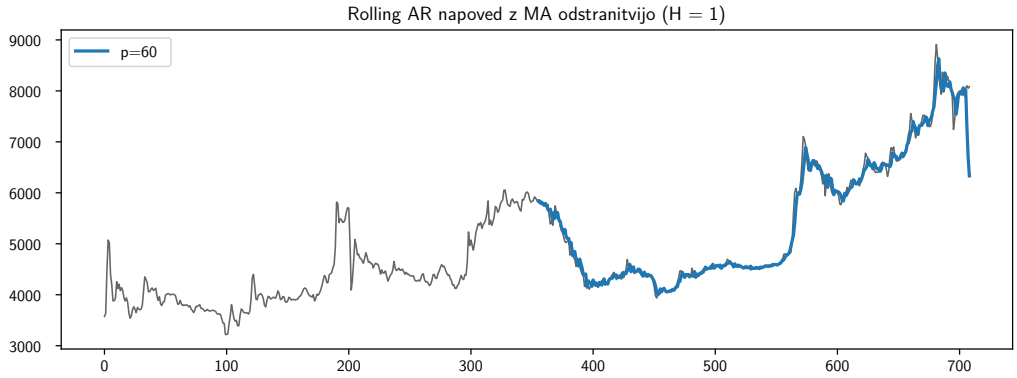

Slika 14